

Projektni zadatak za ocenu 10+ iz predmeta

## Napredni algoritmi i strukture podataka

Školska godina 2023/2024.

### 1. Vremenske serije

Vremenske serije predstavljaju uređeni niz vrednosti neke promenljive zabeleženih najčešće u jednakim vremenskim intervalima (na primer na svakih sat vremena). Dakle, one predstavljaju niz podataka u diskretnim vremenskim tačkama. Na primer, podaci sa vremenskim oznakama, poput log fajlova, metrika aplikacije i sistema ili merenja sa IoT uređaja, mogu se smatrati vremenskim serijama. Pored toga, primer vremenskih serija mogu biti merenja temperature na određenoj meteorološkoj stanici, dnevne vrednosti cena određenih akcija i slično.

Podaci koji se klasifikuju kao vremenske serije poseduju nekoliko osobina koje ih izdvajaju od drugih tipova podataka:

- **Sekvencijalnost:** Podaci u vremenskim serijama su zabeleženi hronološkim redosledom, što omogućava praćenje promena kroz vreme i identifikaciju uzročno-posledičnih odnosa.
- **Nepromenljivost:** Svaka tačka u vremenskoj seriji je zapis nekog događaja i, kada je jednom zapisana, ne očekuje se da će se kasnije menjati.
- **Vremenski intervali:** Podaci se najčešće (ali ne uvek) prikupljaju u pravilnim vremenskim razmacima (sekunde, minuti, sati, dani, godine), što omogućava konzistentnu analizu.
- **Visoka frekvencija podataka:** Merenja se često vrše u kratkim intervalima (svake sekunde ili manje), što je uobičajeno kod IoT uređaja i finansijskih tržišta.
- **Multivarijantnost:** Vremenske serije mogu uključivati više promenljivih koje se beleže istovremeno, npr. temperatura, vlažnost i pritisak na istom mestu.

### 2. Model podataka

Storage engine specijalizovan za rad sa vremenskim serijama treba da podrži model podataka prilagođen njegovoj nameni. Kroz projekat treba da podržite sledeći model:

Jednu **vremensku seriju** jedinstveno identifikuju:

- **Naziv merenja:** Na primer temperatura, procenat osvetljenja, vrednost akcije itd.
- **Skup tagova:** Svaki tag se sastoji iz naziva i vrednosti i služi da bliže odredi vremensku seriju. Na primer, u slučaju gde merimo temperaturu na više lokacija, temperatura na svakoj lokaciji predstavlja po jednu vremensku seriju. Kako bismo ih mogli identifikovati, uz svaku možemo pridružiti tag sa nazivom *lokacija*. Tada bi prva vremenska serija za sebe imala vezan tag *lokacija=Šid*, druga *lokacija=Beograd*, itd.

Jednu **tačku (ili vrednost)** jedinstveno identifikuju:

- **Identifikator vremenske oznake:** Na primer
  - naziv merenja: temperatura
  - tagovi: lokacija=Novi Sad
- **Vremenska oznaka:** Recimo 2024-12-04T15:15:32

Naziv merenja, naziv i vrednost taga treba da budu tipa **string**, dok vrednost merenja treba da bude tipa **float**.

Kroz tabele koje se nalaze ispod ovog teksta možemo videti primer podataka upisanih u storage engine:

		Tagovi		
Naziv merenja	Vremenska oznaka	Lokacija	ID senzora	Vrednost
Temperatura	2024-12-04T15:14:32	Novi Sad	aa:bb:cf:d9:2a:12	12.3
Temperatura	2024-12-04T15:14:32	Beograd	ba:bb:cf:d9:2a:12	10.2
Temperatura	2024-12-04T15:15:32	Novi Sad	aa:bb:cf:d9:2a:12	12.4
Temperatura	2024-12-04T15:15:32	Beograd	ca:bb:cf:d9:2a:12	10.0

		Tagovi		
Naziv merenja	Vremenska oznaka	Lokacija	ID senzora	Vrednost
Vlažnost vazduha	2024-12-04T15:14:32	Novi Sad	aa:bb:cf:d9:2a:12	82.4
Vlažnost vazduha	2024-12-04T15:14:32	Beograd	ba:bb:cf:d9:2a:12	90.1
Vlažnost vazduha	2024-12-04T15:15:32	Novi Sad	aa:bb:cf:d9:2a:12	81.9
Vlažnost vazduha	2024-12-04T15:15:32	Beograd	ba:bb:cf:d9:2a:12	90.3

Iz podataka možemo identifikovati pet vremenskih serija:

- **Prva**
  - **naziv merenja:** Temperatura
  - **tagovi:** lokacija=Novi Sad, ID senzora=aa:bb:cf:d9:2a:12
- **Druga**
  - **naziv merenja:** Temperatura
  - **tagovi:** lokacija=Beograd, ID senzora=ba:bb:cf:d9:2a:12
- **Treća**
  - **naziv merenja:** Temperatura
  - **tagovi:** lokacija=Beograd, ID senzora=ca:bb:cf:d9:2a:12
- **Četvrta**
  - **naziv merenja:** Vlažnost vazduha
  - **tagovi:** lokacija=Novi Sad, ID senzora=aa:bb:cf:d9:2a:12
- **Peta**
  - **naziv merenja:** Vlažnost vazduha
  - **tagovi:** lokacija=Beograd, ID senzora=ba:bb:cf:d9:2a:12

### 3. API

Engine treba da podrži sledeće operacije:

- **WRITE\_POINT** - zapis nove tačke/vrednosti
  - **measurement\_name**: string
  - **tags**: map[string]string
  - **timestamp**: int
  - **value**: float
- **DELETE\_RANGE** - brisanje dela serije koji je u vremenskom opsegu
  - **measurement\_name**: string
  - **tags**: map[string]string
  - **min\_timestamp**: int
  - **max\_timestamp**: int
- **LIST** - dobavljanje serija u navedenom intervalu
  - **measurement\_name**: string
  - **tags**: map[string]string
  - **min\_timestamp**: int
  - **max\_timestamp**: int
- **AGGREGATE** - primena agregacione funkcije nad navedenom serijom
  - **measurement\_name**: string
  - **tags**: map[string]string
  - **min\_timestamp**: int
  - **max\_timestamp**: int
  - **aggregation\_func**: min | max | mean | avg

### 4. Nefunkcionalni zahtevi

**4.1** Engine treba da se sastoji iz struktura optimizovanih za rad sa vremenskim serijama

**4.2** Format podataka na disku možete definisati sami uz oslonac na format koji ste implementirali za regularan projekat ili možete koristiti Parquet<sup>1</sup> format koji biste u tom slučaju implementirali samostalno od nule.

**4.3** Potrebno je, gde je adekvatno, primeniti tehnike kompresije podataka kao što su delta, delta of delta, dictionary kompresiju i ostale tehnike koje ćete istražiti.

**4.4** Engine treba da omogući korisniku da definišete **retention period**. Retention period je vremenski period nakon kog podaci treba da se obrišu. Recimo, ako je retention period 7 dana, sve tačke starije od toga treba tretirati kao obrisane.

**4.5** Duplikate i zastarele podatke potrebno je uklanjati procesom kompakcija.

---

<sup>1</sup> <https://parquet.apache.org/>

## 5. Pomoćni materijali

- <https://docs.influxdata.com/influxdb/v2/reference/internals/storage-engine/>
- <https://docs.influxdata.com/influxdb/v2/reference/internals/file-system-layout/>
- <https://docs.influxdata.com/influxdb/v2/reference/internals/data-retention/>
- <https://www.influxdata.com/blog/compactor-hidden-engine-database-performance/>
- <https://prometheus.io/docs/prometheus/latest/storage/>
- <https://github.com/prometheus/prometheus/tree/main/tsdb>
- <https://ganeshvernekar.com/blog/prometheus-tsdb-the-head-block/>
- <https://tdengine.com/storage-engine-comparison-between-tdengine-and-prometheus/>
- <http://www-cs-students.stanford.edu/~adityagp/courses/cs598/papers/dremel.pdf>