

ЈЕДНОДИМЕНЗИОНЕ НУМЕРИЧКЕ МЕТОДЕ

једнодимензиона
оптимизација

нумеричко
решавање


аналитичко
решавање

методе
директног
оптимизације

методе
апроксимације
градијента

градијентне
методе

- градијентне методе основане су на чињеници да је функција диференцијабилна у области која садржи локално екстремум (тј. $f'(x) = 0$)



Нјутонов - Рајсов метод

$f(x)$ се развija у тачковом ред око x_0

$g(x)$ је изражена линија је екстремум у x_1 , а узима се као нова тачка за следећу итерацију

$$g'(x_1) = 0$$

$$f'(x_0) + f''(x_0)(x_1 - x_0) = 0$$

$$f''(x_0)(x_1 - x_0) = -f'(x_0)$$

$$x_1 - x_0 = -\frac{f'(x_0)}{f''(x_0)}$$

$$x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)}$$

$$x_{k+1} = x_k - \frac{f'(x_k)}{f''(x_k)}$$

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

$$f'(x_k) = \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}}$$

$$x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)}$$

почетно податак:

итеративни податак: $x_{n+1} = x_n - \frac{f'(x_n)}{f''(x_n)}$

критеријум заустављања:

$$\epsilon_{n+1} = \left| \frac{x_{n+1} - x_n}{x_{n+1}} \right|$$

конвергенција ЗАВИСИ ОД
ДОБРОГ ПОЧЕТНОГ ПОДАТАКА

x_{n+1} - вредност наредне итерације

x_n - тренутна вредност

$f'(x_n)$ - први извод функције у тачки x_n

$f''(x_n)$ - други извод функције у тачки x_n

ϵ - толеранција

- принцип рада: да се унапред одреди макс. број итерација, јер ако се не одбере добро почетно податак, алгоритам може да конвергира и први критеријум никак неће бити задовољен

Метод секунце

- основна разлика: обе методе итеративно се израчунавају, али се овде израчунавају и други изводи


$$f''(x_n) = \frac{f'(x_n) - f'(x_{n-1})}{x_n - x_{n-1}}$$

итеративна формула:

$$x_{n+1} = x_n - f'(x_n) \frac{x_n - x_{n-1}}{f'(x_n) - f'(x_{n-1})}$$


- није потребно да функција буде диференцијабилна до другог извода, али у овом случају неће бити проблема. одговор добро почетног интервала, омогућавамо алгоритму да конвергира ка оптимуму. Овај алгоритам се смањивао брзину конвергенције у поређењу са Нјутоновим методом

- Метод директног дифрагирования основан на методе деления отрезка на части и использовании их "критерия" нелинейных оптимизационных алгоритмов и сводится к ПРИБЛИЖЕННОМУ ЗАКРЫТОМУ ИНТЕРВАЛУ; число делений n зависит от ϵ и функции $f(x)$




делают дифрагирование за N шагов где ϵ - разрешение

$$N = \frac{b-a}{\epsilon} + 1$$



$$f(x_1) < f(x_2) < f(x^*) \text{ ако је } x_1 < x_2 < x^*$$

$$f(x^*) > f(x_3) > f(x_4) \text{ ако је } x^* < x_3 < x_4$$



дифрагирование до тех пор пока не найдем $\min f(x)$:

0) определяем интервал $[a, b]$

$$1) \text{ на } x_1 = a + \frac{b-a}{2} \left(-\frac{\epsilon}{2} \right) \quad x_2 = a + \frac{b-a}{2} + \frac{\epsilon}{2}$$



2) определяем $f(x_1)$ и $f(x_2)$

3) ако је $f(x_1) < f(x_2)$, елиминируем $x > x_2$ и $b = x_2$

ако је $f(x_1) > f(x_2)$, елиминируем $x < x_1$ и $a = x_1$

ако су равны, беремо оба интервала

4) останавливаемся пока не будет $\leq 2\epsilon$



- функция је унимодальна якщо има один локальний екстремум на заданном интервалу
тоді її єдиний і глобальний екстремум на тому інтервалу

Фибоначчів метод

1. одр. інтервал $L_0[a, b]$ ($a < b$) коті садрити x^* и ситуирирати резолюцію ϵ
2. одр. найменш др. др. n коті задовольняє

$$F_n > \frac{1}{\epsilon}(b-a) \quad \text{или} \quad F_n > \frac{L_0}{\epsilon}$$

3. взр. дроби інтервал:

$$x_1 = a + \frac{F_{n-2}}{F_n}(b-a)$$

$$x_2 = a + b - x_1$$

4. взр. k -ий інтервал и обчислювати пошуток

$f(x_1) \leq f(x_2)$ елиминіруемо $x > x_2$ и $b = x_2, x_2 = x_1, x_1 = a + b - x_1$ ИСТО

$f(x_1) > f(x_2)$ ели. $x < x_1$ и $a = x_1, x_2 = x_1, x_2 = a + b - x_2$

$f(x_1) = f(x_2)$ нови дроби почати

Метод знайти середнє

$$\frac{F_{n-2}}{F_n} \approx \frac{3-\sqrt{5}}{2} = 0.38196$$

$b-a < \epsilon$ - критерій
завершення

1. одр. інтервал $L_0[a, b]$ ($a < b$) коті садрити x^* и ситуирирати резолюцію ϵ

2. израхувати $c = \frac{3-\sqrt{5}}{2}$

3. взр. дроби інтервал:

$$x_1 = a + c(b-a)$$

$$x_2 = a + b - x_1$$

4. доки $(b-a) < \epsilon$:

$f(x_1) \leq f(x_2)$ елиминіруемо $x > x_2$ и $b = x_2, x_2 = x_1, x_1 = a + c(b-a)$

$f(x_1) > f(x_2)$ елиминіруемо $x < x_1$ и $a = x_1, x_1 = x_2, x_2 = b - c(b-a)$

$f(x_1) = f(x_2)$ нови дроби почати

ВИШЕДИМЕНЗИОННЕ ЧУМЕРИЧКЕ МЕТОДЕ

Метод најбржег пада

- Градијентни-вектор који показује смер и брзину највеће промене ф-је
- рецимо ако имамо ф-ју са више променљивих, градијентни из ф-је ∇f је вектор који садржи парцијалне изводе функције по свакој променљивој

$$\nabla f(x, y, z) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y}, \frac{\partial f}{\partial z} \right)$$

промена ф-је f када мењамо само x (у и z су конст.)

- вектор градијентна указује смер највеће промене брзине ф-је
- овим методом истражи се минимум диференцијабилне ф-је $f(x) = f(x_1, x_2, \dots, x_n)$ тако што се у свакој итерацији решење помера у правцу негативног градијента од f

$$\nabla f = \left[\frac{\partial f}{\partial x_1} \frac{\partial f}{\partial x_2} \dots \frac{\partial f}{\partial x_n} \right]^T$$

1. иницијални запис: одбере се почетно покретно, корак $\mu > 0$, и операција $\epsilon > 0$, макс. број корака N

2. иако метод који аритметички итеративно:

$$x_{k+1} = x_k - \mu \nabla f(x_k)$$

3. критеријум заустављања - на крају сваке итерације проверавамо $\|\nabla f(x_k)\| \leq \epsilon$

Метод најбржег пада са моментумом

$$V_k = w V_{k-1} + \mu \nabla f(x_k)$$

$$x_{k+1} = x_k - V_k$$

- даје моментум одн. смер претходног градијента у израчунавању како би се осигурали смањиве

V - вектор брзине који садржи инфо. о претходном правцу кретања

w - коэф. моментума (колико памтимо претх. правцу) - типично између 0 и 1

- ради тако што пуца правцу претх. корака да би стандардизовало правцу у правцу мин.
- смањива конвергенцији и смањење осцилација у близини минимума
- међутим, од смањења параметара може бити компликовано

основан фактом са чијом се свако различитим алгоритмом је што је
 врхуна адаптивност или до свих осам, што значи да је немогуће одређити параметре
 када се примењују знате друге мере до друге осам или до друге

ако МАЛА ПРОМЕНА може променити доводи до ВЕЛИКИХ ПРОМЕНА К.О. - променљиву
 метални
 постоје

ако МАЛА ПРОМЕНА може променити доводи до НЕЗНАТНИХ ПРОМЕНА К.О. - променљиву
 метални
 број
 са великом
 користи

дакле факта адаптивност треба да буде иста за сваку осу

Адаптив (адаптивни градијент)

$$X_{k+1,i} = X_{k,i} - \frac{\eta}{\sqrt{G_{k,i} + \epsilon_1}} g_{k,i}$$

η - градијент функције у итерацији интеракција (мере промене
 за сваку променљиву)

G - сума квадрата свих претходних градијената

η - параметар учешћа у свакој итерацији, а не у свакој променљиву
 и зависност од ϵ

ϵ_1 - мали параметар који се регулише израза у итерацијама (да не делимо)
 (10⁻⁸)

основан фактом јесте акумулација градијената у величини G (који се константно повећава)
 временом повећава. Ово доводи до ефективног смањивања дужине свих корака до свих
 димензија, а што се ефикасност алгоритма из интеракција у интеракцију смањује.

Решавамо шта РАЧУНА СУМА КВАДРАТА ПРЕТХОДНИХ ГРАДИЈЕНАТА како би
 факторисали корак у свакој интеракцији

Адам (адаптивно проучавање момената)

Једна је од најчешће коришћених садржајних модификација алгоритма градијентног

$$m_k = w_1 m_{k-1} + (1-w_1) g_k$$

$$\hat{m}_k = \frac{m_k}{1-w_1}$$

$$v_k = w_2 v_{k-1} + (1-w_2) g_k^2$$

$$\hat{v}_k = \frac{v_k}{1-w_2}$$

$$X_{k+1} = X_k - \frac{\eta}{\sqrt{\hat{v}_k + \epsilon_1}} \hat{m}_k$$

g - градијент функције у итерацији интеракција, смер у којем се врши оптимизација за сваку
 променљиву

m - ПРОСЕЧНИ ГРАДИЈЕНТ (први моменат) до итерације интеракције, што помаже да се
 убави дужина смер кретања у оптимизацији

v - ПРОСЕЧАН КВАДРАТ ГРАДИЈЕНТА (други моменат) што помаже да се контролише
 величина корака и убави брзина промена у градијентима

w_1, w_2 - коефицијенти за експоненцијално убављивање првог и другог момената
 (обично вредности 0.9 и 0.999)

ϵ_1 - мали број да избегне делове нулом (обично 10⁻⁸)

η - почетна учешћу у свакој итерацији са η тако да кораци брзо стабилизују и
 прилагођавају различитим променљивим