

## LINEARNA REGRESIJA

1. Navedite model **višestruke linearne regresije** i objasnite sve oznake.
  - $y = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n + \text{epsilon}$
  - $y$  – predviđana vrednost
  - $b_0$  – intercept, vrednost  $y$  kada su sve  $x_i = 0$
  - $b_i$  – parametri koji predstavljaju uticaj svake nezavisne promenljive
  - $x_i$  – nezavisne promenljive koje se koriste za predviđanje
  - epsilon – greška modela
2. Objasnite čemu služi koeficijent determinacije ( $R^2$ ).
  - Procena koliko se dobro regresioni model uklapa u podatke.
  - Kreće se između 0-1.
  - 0 – nikakvo uklapanje.
  - 1 – savršeno uklapanje.
  - $R^2 = 0.72$  - 72% varijacije u  $y$  možemo objasniti pomoću  $x$ , 28% varijacije je šum koji nije obuhvaćen modelom.
3. Objasnite šta se optimizuje pomoću **Metode Najmanjih Kvadrata**.
  - Minimizujemo grešku, odnosno razliku predikcija i stvarnih vrednosti sa ciljem da dobijemo parametre modela.
4. Definišite **zbir kvadrata grešaka** regresionog modela koristeći koje god oznake želite.
  - $$\frac{1}{N} \sum_{i=0}^N (y_i - \hat{y}_i)^2$$
5. Objasnite zašto je regresija pomoću polinoma **trećeg stepena takođe lin reg.**
  - Linearna je po parametrima, ne po nezavisnoj promenljivoj.
6. Objasnite čemu služi **t-test**.
  - Služi za testiranje statističke hipoteze. Postavimo hipotezu lošeg slučaja – da je parametar = 0, ako je p-vrednost < 0.05 odbacujemo hipotezu, znači da je taj parametar različit od 0. To znači da postoji linearna veza između  $y$  i  $x$  uz koji stoji taj parametar.
7. Na koji način se interpretira **p-vrednost sa 95% pouzdanosti**.
  - $p < 0.05$  odbacujemo hipotezu da ne postoji linearna veza između  $y$  i  $x$ , odnosno postoji linearna veza.
8. Objasnite na koji način se interpretira **koeficijent regresionog modela** kod **višestruke lin reg.**
  - Ako povećam neko  $x$  za 1 vrednost, koliko će se povećati srednja vrednost  $y$  ako su ostali  $x$  fiksirani.
9. Ako je dat regresioni model za predikciju cena kuća koji uključuje površinu kuće i broj kupatila, kod koga koeficijenta ispred površine kuća ima **negativnu vrednost  $b_p$**  na koji način se interpretira ta negativna vrednost.
  - Cena kuće opada sa povećanjem površine, ako je fiksiran broj kupatila – npr. ogromna kuća sa 1 kupatilom.
10. Objasnite zašto nam je kod višestruke regresije potreban **prilagođeni koeficijent determinacije**.
  - $R^2$  – kako dodajemo promenljive biće isti ili rasti, ne znamo da li smo overfitovali i da li su dodate promenljive besmislene, dok prilagođeni uzima u obzir broj nezavisnih promenljivih.
11. Objasnite pojam preprilagođavanja **overfittinga**.

- Model je loše uslovljen, za male promene x dobijam velike promene y. Kreće da se prilagođava ne samo signalu nego i šumu.
- Objasnite na koji način možete da utvrdite da li je neka nezavisna promenljiva korisna u modelu višestruke lin reg.
    - Kod promenljivih kod kojih je p-vrednost  $< 0.05$  te su korisne jer odbacuje hipotezu da je 0, znači da postoji linearna veza, odnosno parametri uz x su različiti od 0.
  - Objasnite u kojoj situaciji nije dobro ukloniti nezavisnu promenljivu koja ne doprinosi modelu višestruke regresije.
    - Cilj predikcija – možemo da uklonimo iz modela ako nam nije korisna.
    - Cilj istraživanje – hoćemo da vidimo baš vezu između te promenljive i y.
  - Navedite pretpostavke lin reg. (LINE)
    - Linearity - Linearnost podataka.
    - Independence of errors (nezavisnost grešaka) -  $y_i$  ne zavisi od  $y_{i-1}$ , ako zavisi onda je model vremenskih serija, a na grafiku reziduala – greške ravnomerno osciluju.
    - Normality of errors - Greške prate normalnu raspodelu - najverovatnije će podatak biti na samom regresionom modelu, sa malo manjom verovatnoćom će biti udaljen.
    - Equal variance - konstantna varijansa greški – ne valja ako su na početnom grafiku greške manje pa kasnije veće, reziduali ne smeju da imaju šablon.
  - Objasnite pretpostavku o linearnosti.
    - Postoji linearna veza između x i y. Ako je narušena radimo transformaciju npr.  $x^2$
  - Objasnite pretpostavku o nezavisnosti grešaka.
    - Nezavisnost grešaka  $y_i$  ne zavisi od  $y_{i-1}$ . Ako je narušena onda se koristi model vremenskih serija.
  - Objasnite pretpostavku o multikolinearnosti.
    - npr.  $x_1 = 2x_2 + x_3$  -> problem ako rešavamo sa metodom najmanjih kvadrata jer tada rešavamo sistem sa d jednačina i d nepoznatih, a ako su neki u međusobnoj vezi dobili bismo da sistem nema rešenja.
    - Ako imamo približnu multikolinearnost onda je model nestabilan, skloniji smo overfittingu.
  - Objasnite pretpostavku o konstantnoj varijansi grešaka.
    - Na početnom grafiku su greške manje pa kasnije veće.
    - Onda možemo da probamo logaritamsku ili korensku transformaciju y.
  - Objasnite šta su reziduali modela.
    - $y_i$  (stvarno) –  $y_i$  (predviđeno) je rezidual.
  - Koja pretpostavka je narušena na datom grafiku (slika).
    - Nezavisnost grešaka. Radili bismo modelom vremenskih serija.
  - Koja pretpostavka je narušena na datom grafiku reziduala (slika).
    - Equal variance. Na početnom grafiku greške manje pa veće kasnije, a na grafiku reziduala – greške ne osciluju ravnomerno.

## INTERPOLACIJA

1. Opišite **problem** koji rešavamo interpolacijom i objasnite kako ga rešavamo (navedite osnovnu ideju, nije neophodno da navodite konkretan postupak ili formulu).
  - Imamo skup tačaka i hoćemo da vidimo šta se dešava između tih tačaka. Interpolacija - pretpostavka da će to biti interpolacioni polinom koji precizno prolazi kroz svaku od tačaka.
2. U kom slučaju biste primenili **interpolaciju**, a u kom **regresiju**?
  - Regresiju kada tražimo trend u podacima – cena nekretnine za istu kvadraturu ima prodate kuće za različitu cenu. Interpolacija - merenja su precizna – npr. zvuk, slika i izmereni podaci ostaju takvi kakvi jesu pa tražimo samo šta je između podataka.
3. Nepoznata funkcija  $f$  je zadata u  $N$  tačaka. Interpolacijom određujemo jedinstven polinom koji prolazi kroz svaku od zadatih tačaka: (1) Napišite oblik traženog **polinoma**, koje parametre određujemo interpolacijom i koliko ih ima. (2) Ukoliko je stepen polinoma **prevelik**, koju alternativu možemo da primenimo?
  - $y = a_0 + a_1x + a_2x^2 + \dots + a_{n-1}x^{n-1}$ , određujemo  $n$  parametra od  $a_0$  do  $a_{n-1}$ .
  - splajn – na svakom intervalu imamo poseban splajn, npr. linearni, kvadratni.
4. Kako se polinom predstavljaju u **Pythonu**? Napišite predstavu polinoma  $5.5 \cdot x^3 + x - 3$ .
  - Kao vektori,  $[5.5 \ 0 \ 1 \ -3]$ .
5. U interpolaciji, kada određujemo jedinstven polinom stepena  $N-1$  koji prolazi kroz  $N$  zadatih tačaka, oblik polinoma možemo predstaviti na dva načina: (1) standardni zapis  $g(x) = a_1 + a_2x + a_3x^2 + \dots + a_Nx^{N-1}$ , (2) Lagranžov zapis i (3) Njutnov zapis. Zašto određivanju interpolacionog polinoma tipično ne koristimo standardni zapis polinoma, već druge **alternative**?
  - Kod standardnog zapisa –  $n$  jednačina sa  $n$  nepoznatih, problem je loš uslovljen sistem jer za male promene podivlja rešenje. (crtež skoro 2 paralelne prave)
6. U interpolaciji, kada određujemo jedinstven polinom stepena  $N-1$  koji prolazi kroz  $N$  zadatih tačaka, oblik polinoma možemo predstaviti na dva načina: (1) standardni zapis  $g(x) = a_1 + a_2x + a_3x^2 + \dots + a_Nx^{N-1}$ , (2) Lagranžov zapis i (3) Njutnov zapis. Navedite **Njutnov zapis** polinoma drugog stepena.
  - $g_N(x) = b_1 + b_2(x-x_1) + b_3(x-x_1)(x-x_2)$
7. U interpolaciji, kada određujemo jedinstven polinom stepena  $N-1$  koji prolazi kroz  $N$  zadatih tačaka, oblik polinoma možemo predstaviti na dva načina: (1) standardni zapis  $g(x) = a_1 + a_2x + a_3x^2 + \dots + a_Nx^{N-1}$ , (2) Lagranžov zapis i (3) Njutnov zapis. Navedite **Lagranžov zapis** polinoma drugog stepena.
$$g_L(x) = \frac{(x-x_2)(x-x_3)}{(x_1-x_2)(x_1-x_3)}f(x_1) + \frac{(x-x_1)(x-x_3)}{(x_2-x_1)(x_2-x_3)}f(x_2) + \frac{(x-x_1)(x-x_2)}{(x_3-x_1)(x_3-x_2)}f(x_3)$$
8. U interpolaciji koja **dva faktora** utiču na tačnost procene dobijene interpolacionim polinomom?
  - Razdaljina tačaka – što je manja biće preciznije.
  - Broj tačaka – stepen polinoma kako se povećava dobijamo preciznije rezultate.
9. U interpolaciji, kada određujemo jedinstven polinom stepena  $N-1$  koji prolazi kroz  $N$  zadatih tačaka, oblik polinoma možemo predstaviti na dva načina: (1) standardni zapis  $g(x) = a_1 + a_2x + a_3x^2 + \dots + a_Nx^{N-1}$ , (2) Lagranžov zapis i (3) Njutnov zapis. Koja je **prednost Njutnovog zapisa** nad njegovim alternativama?

- Ako dodamo još jednu tačku, odnosno uvećamo stepen interpolacionog polinoma, oni niži koeficijenti ostaju nepromenjeni pa bismo računali samo još jedan dodatni koeficijent.
10. Šta je **ekstrapolacija**?
- Koristimo isti polinom kao kod interpolacije koja nam govori šta se dešava između tačaka, a kod ekstrapolacije šta se dešava daleko od tih tačaka i trudimo se da ekstrapolaciju izbegnemo.
11. Opišite osnovnu ideju **interpolacije splajnom**.
- Podelimo interval  $N-1$  ako je  $N$  broj tačaka. Na svakom intervalu imamo poseban splajn i na kraju dobijemo krivu koja prolazi kroz sve tačke.
12. Skicirajte interpolaciju splajnom. Šta je **problem** kod **linearnog** splajna?
- Problem - koristi linearni polinom pa kriva može da ne bude dovoljno glatka i da onda ne prati baš precizno oblik podataka.
13. Skicirajte interpolaciju kvadratnim splajnom za 4 tačke – naznačite oblik polinoma za svaki od podintervala i koliko ukupno nepoznatih koeficijenata moramo da odredimo (slika).