Beilage zu [illegible]

[illegible]

- када тестирамо проценте / пропорцију - радимо prop.test или Binom

1) О: НЕПОЗНАТЕ ВЕРОВАТНОЋЕ

2) стварни проценат: не дирати!

3) Ho: код процената увек пази непознати проценат је X% ↗15%
одн. Ho(p=x) → 0,15

4) prop test је ПАРАМЕТАРСКИ

- параметарски тестови - тестирају тачне параметре популац. (ар. ср. или пропорција) и унапред претпостављају да подаци прате неку расподелу (нпр. нормалну расподелу)

prop.test, t.test, ANOVA

- Непараметарски тестови - не рачунају их параметри већ тестирају облик расподеле, медијане, рангове и не захтевају претпоставку о нормалности

Хи-квадрат

5) p-value: $p<0,05$ → одбацујемо хипотезу - води рачуна к/с хипотез
$p>0,05$ → прихватамо

- када тестирамо средњу вредност - радимо студентов t-test

1) О: ОЧЕКИВАЊУ

2) средња вр. коју су ми оставили: на дну пише!

3) Ho (m=3.5) → Ho је увек нешто = од из текста задатка
а ~~Но~~ води рачуна шта ће нас занимати, овде је H₁ (m>3.5)

alternative = "greater", "less" или "two sided"
↓
искључиво зависи од тога шта нам је H_1!

4) t.test је ПАРАМЕТАРСКИ

5) увек тражи p= ... да ли је то веће од 0,05 ⇒ прихват/одбацуј
а ако се тражи алт. хипотеза стави само супротно!

- када тестирамо ср. вр. али немамо конкретан број него упоређујемо две групе || t.test

али прво што радимо `var.test(gp1,gr2)`
и гледамо p вр → ако је > 0,05 у t.test морамо да додамо
`t.test(gr1,gr2,alternative="greater", var.equal= TRUE)`

1) Средње вр. за обе групе: на дну тога
2) студентов t-test, ПАРАМЕТАРСКИ
   - код var ако је $p > 0,05$ → студентов (t test са једнаким варијан
   - $p < 0,05$ → welch-ов (неједнаким)
3) $H_0: (m_x = m_y)$, $H_1(m_x > m_y)$ итд.
4) реализована вр. тест статистике: t = ___ у реду тога
5) p-вр

2. задатак

- чим се у задатку тражи независност → одмах знамо да је реч о хи-квадрат тесту X^2 ①↓ ②↓ ③↓ → овако се уносе подаци

1) Пирсонов X^2 тест (може и табела контингенције, али је ово боље!)
   НЕПАРАМЕТАРСКИ
2) H_0 увек (код X^2 теста) - посматрана обележја су независна
   (H_1 - посматрана обележја су зависна)
3) реализована вр. тест статистике: X-squared: број (ово!)
4) са квантилом које расподеле, колико степени слободе: X^2_4 → df из таблице или (бр редова-1)×(бр кол
5) p-вр

– када тестирамо да ли неки подаци прате тачно одр. облик/расподе
користимо **‖Колмогоров – Смирнов тест‖**

1) НЕПАРАМЕТАРСКИ (не занима га само просек, већ га занима комплет облик и цела крива расподеле)

2) H_0: (тврдња се испитује) + колона има ту и ту расподелу

3) макс. одступање емпиријске од теоријске ф-је расподеле (dn : 0,12475)
у првом кораку извуци

4) реализована вр. тест статистике – др. линија
D из вр. и упоређује се са $\lambda_{0,95} = 1.36$

$\boxed{\lambda_{0,95} = 1,36}$ → ово је оно што се гледа у таблици за разл. α од разл. вредности

реализ. вр. > 1,36 – одбацујемо H_0
реализ. вр. < 1,36 – прихватамо H_0
→ др. линија се увек гледа кад нам треба λ!

– да испитамо сагласност нечега са нормалним расподелом помоћу **‖χ^2 теста:‖** –

1) (f) пише изнад табелу
2) тачна вероватноћа за одр. интервал (p)
3) НЕПАРАМЕТАРСКИ
5) реализована вр. хи-сквер: (–)!
4) ___ има ___ код расподелу?! ?
6) квантил $\chi^2_{(4)}$ → бр интервала − 1 (− бр парам. које смо оценили)
7) p-вр.

– ако није дат парам. него мора нпр. $\mathcal{N}(m, 3.14)$
↓
рач. као prosek ← mean(podaci$HP

3. задатак

- код **ANOVA-е**:

1) H_0 је увек средње вр. свих обележја су једнаке $H_0 (m_x = m_y = m_z \dots)$
2) обележје које се испитује - буде једно користи само
3) ФИШЕРОВА - увек када имамо ANOVA-у се пишемо!
4) бр. степени слободе - Df (–) (–) —/ ид!
5) реализована вр. - F value (–)
6) p-вр Pr>F (–)

! 4 питања за ANOV-у увек!

- 2) само ако питају нивое фактора - набрај све који се јављају - нпр. пон, уто, сре, чет
  5) ако пита за значајне разлике - то пита за H_1!

- 1) имаш estimate
  intercept (–) → бр = 1.бр + 2.бр * Bill + 3.бр * size
  Bill —
  size —
  2) уместо Bill и size убацити што је задато
  3) подвући коеф. детерминације - adjusted (–)
  4) p-вр (–)
  5) $p < 0,05$ → одбацује се, МОДЕЛ ЈЕ ЗНАЧАЈАН
  $p > 0,05$ → НИЈЕ ЗНАЧАЈАН!

! 2 питања за регресију
- само за модел и summary

- вр. по ком се ради ANOVA мора бити КАТЕГОРИЈАЛНО ОБЕЛЕЖЈЕ

- Видимо како [illegible] csv!
- [illegible] - [illegible] обје и на који начин [illegible]!

```
nes <- pod$pest[pod$smok = "NO"]
sd(nes)
```

df = length(nes) - 1

$p > 0,05$ → НОРМАЛНА РАСПОДЕЛА!

```
podaci ← read.csv ("tips.csv")
view(podaci)
```

Вежбе 16 (СНИМАК 25.9.2025.)
од 59.45

| А група |

- требаће нам тест који тестира неку хипотезу непознату вероватноћу - ту смо имали
- binom test - права вр коју нам враћа
- prop test - вр која се добије када се примени апроксимација (непрекидно обележје мењамо дискретним код Моавр Лапласове теореме

```
k ← length (which (podaci$tip<2))
n ← length (podaci$tip)
binom.test (k,n, 0.15)
prop-test (k,n, 0.15, correct =FALSE)
```

← чешће ово кор.

Учитати фајл tips.csv. Праг значајности у свим задацима је $\alpha = 5\%$. ← ТАЧНО

1. Тестирати хипотезу да проценат напојница (tip) које су мање од 2$ износи 15%.

a) У зад. се тестира хипотеза о непознатој вероватноћи

б) На основу датог узорка процењени проценат износи 0,1875

в) Нулта хипотеза овог теста гласи непознати проценат је 15%. или $H_0(p=0,15)$

d) Тест који се користи спада у групу [✓ параметрских]/непараметарских статистичких тестова

↓ јер ми покушавамо да откријемо нешто за вр. непознатог парам p

e) p вредност добијена тестом износи 0,1041, одакле закључујемо да је оправдано [✓ прихватити] / одбацити хипотезу да проценат напојница које су мање од 2$ износи 15%.

јер је p вредност веће од 0,05

овај одговор зависи само од вр. која треба овде да се упише

→ неки непараметарски тест

2. Посетиоци пијаце су одговарали на питање који им је омиљени укус сладоледа. Испитати независност посматраних обележја ако су добијени следећи резултати:

	vanila	cokolada	jagoda
muskarci	38	65	35
zene	30	68	28
deca	60	109	67

- табела контингенције ради се тако што се само хи-квадрат тесту проследи табела која нам је дата у задатку

```
~~cisq.test~~ (matrix ( c (38, 30, 60, 65, 68, 109,
chisq.test   35, 28, 67), 3, 3))
```

a) Тест који се користи зове се Пирсонов χ^2 тест ← признали би и да неко напише табела контингенције али заправо то је Пирсонов χ^2 тест
и спада у групу параметарских / [✓ непараметарских] тестова

↓ не причамо о параметрима него о расподели да ли су обележја независна

в) Нулта хипотеза овог теста гласи посматрана обележја су независна

c) Реализована вредност тест статистике износи 2,6885

d) Са квантилом које расподеле (и са колико степени слободе!) се ова вредност упоређује χ^2_4

бр степени слободе: (колико имамо бр за групу - 1) × (за сладолед колико имамо бр - 1)

$4 = (3-1) \times (3-1)$

e) p вредност добијена тестом износи 0,6112, на основу овога закључујемо да је оправдано [✓ прихватити]/ одбацити хипотезу о независности обележја група и сладолед

↓ p вредност је велика

*** → оно што може да се деси јесте да не добијемо табелу, него да ми сами треба да на основу табле прво извучемо фреквенције па онда да радимо овај облик хи-квадрат теста ***

*** 3. зад. ће бити ANOVA или регресија ***

3. Тестирати хипотезу о једнакости средње вредности рачуна (Bill) по данима (ANOVA).

```
boxplot (Bill~day, data=podaci)
podaci $ day=as. factor (podaci$day)
summary (podaci$day)
```

- ANOVA је када тестирамо у неколико група да ли су исте средње вредности

обим узорка - број фактора
240-4

a) Нулта хипотеза овог теста гласи H_0 ($m_{\check{c}} = m_p = m_s = m_n$)

b) обележје које се испитује је износ рачуна (Bill)

број нивоа фактора - 1
4-1

c) тест статистика Фишерову расподелу са бројевима степена слободе 3 и 236

ниже
Df
3
236

d) Реализована вредност тест статистике износи 2,8887 ← F-value 2,8827

e) p-вредност добијена тестом износи 0,03654 што значи да се H_0 прихвата/[✓ не прихвата]

Pr (>F)
0,03654

алтернативна би гласила H_1 ($\exists i,j$, $m_i \neq m_j$)

Учитати фајл tips.csv. Праг значајности у свим задацима је $\alpha=5\%$ | В група |

1. Тестирати хипотезу да је средња вредност напојница (tip) које су мушкарци остављали веће од 3,5 $.
↳ неко очекивање

a) У задатку се тестира хипотеза о очекивању $\sigma = ? \rightarrow$ t test

b) Средња вредност напојнице које су мушкарци остављали износи 3,103636 → избаци тест

c) Нулта хипотеза овог теста гласи $H_0 (m=3,5)$

нас не занима та хипотеза, него $\boxed{H_1 (m>3,5)}$ ← биће нам интересантно шта се дешава са овом алтернативном хипотезом (не нултом)

d) тест који се користи спада у групу [✓ параметарских]/непараметарских статистичких тестова
↓ причамо о непознатом параметру

e) p-вредност добијена тестом износи 0,9994, одакле закључујемо да је оправдано прихватити/[✓ одбацити] хипотезу да је средња вредност напојница које су мушкарци остављали веће од 3.5 $

```
t.test (podaci$tip [podaci$sex == "Male"], mu= 3.5, alternative = "greater")
```

↓ не предамо целу колону tip, предамо само део за мушкарце

H_0 V ⇒ H_1 X

пажљиво читати текст зад. да ли се пита за алтернативну или нулту хипотезу

2. Колмогоров-Смирнов тестом тестирати хипотезу о сагласности износа рачуна (bill) са нормалном расподелом $N(20,9)$
Колмогоров смирнов тес је тест који се бави расподелом ↑

a) Колмогоров-Смирнов тест спада у групу параметарских/[✓ непараметарских] тестова

$D = 0,12475$

b) Нулта хипотеза овог теста гласи bill има $N(20,9)$

c) Максимално одступање емпиријске од теоријске функције расподеле (d_n) износи 0,12475

d) Реализована вредност тест статистике износи 1,932572 и она се упоређује са квантилом $\lambda_{0,95} = \overset{\sqrt{n}D_n}{1,36}$ ← има, не одговара

e) p-вредност добијена тестом износи 0,00114, што значи да се H_0 прихвата/[✓ не прихвата]
↓ јер је реализована вр. веће од највеће дозвољене

```
ks.test (podaci$bill, 'pnorm', 20, 9)
ks.test (podaci$bill, 'pnorm', 20,9)$static*sqrt (lengtt (podaci$bill))
```
← реализована вр.

→ да занемаримо ако се појави warning. KS тест се буни ако се у узорку појаве вредности које су исте

Водити рачуна да не помешамо:

d_n - максимално одступање емпиријске од теоријске фје расподеле → онај супремум $\sup|\quad|$
↑ разлика фје расподеле и емпиријске фје расподеле

→ Шапировим тестом бисмо могли да проверимо да ли имамо нормалну расподелу

3. Тестирати хипотезу о једнакости средње вредности висине напојница (tip) по данима (ANOVA).

a) Нулта хипотеза овог теста гласи $H_0(m_č = m_p = m_s = m_n)$

b) Нивои фактора по ком се ради ANOVA су четвртак, петак, субота, недеља

c) тест статистика има Фишерову расподелу са бројевима степени слободе 3 и 236

d) Реализована вредност тест статистике износи 1,7914 { F-value 1,7914 }

e) p-вредност добијена тестом износи 0,1495, што значи да постоје/[✓ не постоје] статистички значајне разлике између нивоа. { p-value 0,1495 } ⇒ H_0 V
↓ $m_i \neq m_j$ ↓ $m_1=m_2=m_3=m_4$ јер смо прихватили H_0

```
boxplot (tip~day, data=podaci)
anova (lm (tip~day, data =podaci))
```

– водити рачуна ако добијемо нумеричке вредности да их онда прво претворимо у фактор јер кад су нумеричке вр. он ради [illegible] ANOVу која није ова ANOVA коју ми знамо да урадимо

| С група |

Учитати фајл tips.csv. Праг значајности у свим задацима је α = 5%.

1. Тестирати хипотезу да је средња вредност напојница (tip) коју су мушкарци остављали [✓ већа] од средње вредности напојница које су жене остављале.

a) Мушкарци су просечно за напојнице остављали 3,103636 $, а жене 2,819884 $

b) Тест који се користи за упоређивање средњих вредности напојница које су остављали мушкарци и жене зове се Студентов t-test и спада у групу [✓ параметарских]/непараметарских тестова

↓ причамо о средњ. вр.

c) Нулта хипотеза овог теста гласи $H_0(m_m = m_ž)$, а алтернативна хипотеза је $H_1(m_m > m_ž)$

→ овде је алтернативна хипотеза оно што нам је битно

d) Реализована вредност тест статистике износи 1,6326 | t = 1,6326 |

e) p-вредност добијена тестом износи 0,05201, одакле закључујемо да је оправдано прихватити/ [✓ одбацити] хипотезу да је средња вредност напојница коју су мушкарци остављали [✓ већа] од средње вредности напојница које су жене остављале.

$H_0 V \Rightarrow H_1 X$

p вредност је мало веће од 0,05!

```
tipM ← podaci$tip [podaci$sex == "Male"]
tipZ ← podaci$tip [podaci$sex == "Female"]
var.test (tipM, tip2)  ← да видимо која нам варијанта t-теста треба
t.test (tipM, tipZ, alternative = "greater")
```

```
m ← c( 1.5, 2.5, 3.5, 5)
pm ← pnorm (m, 3, 1.4)
p ← c(pm, 1) - c(0, pm); round (p, 4)  ← овде је одг. за питање под b)
mi ← c (floor (min (podaci$tip)), m, celing (max (podaci$tip)))
fi ← hist (podaci$tip, mi) $ counts  ← враћа оно што уписујемо у табелу
chisq.test (fi, p=p)
```

2. χ^2-тестом испитати сагласност висине напојница (tip) са нормалним расподелом $\mathcal{N}(3, 1.4)$. Узорак поделити на пет интервала користећи деобне тачке 1.5, 2.5, 3.5 и 5.

a) Попунити табелу фреквенција за дате интервале.

(-∞, 1.5]	(1.5, 2.5]	(2.5, 3.5]	(3.5, 5]	(5, ∞)
26	80	72	44	18

тестирало да ли имамо нормалну расподелу
↑ причамо о врсти расподеле

може и 72 / обим узорка
↑

b) Колика је вероватноћа да износ напојнице припада интервалу [2.5, 3.5] 0,2790

c) χ^2-тест спада у групу параметарских/ [✓ непараметарских] тестова

d) Нулта хипотеза овог теста гласи tip има $\mathcal{N}(3, 1.4)$

e) Реализована вредност тест статистике износи 25,338 → | X-squared 25,338 |

број интервала − 1

f) Са квантилом које расподеле (и са колико степени слободе!) се ова вредност упоређује? χ^2_4 (5−1)

g) p-вредност добијена тестом износи $4,302 \cdot 10^{-5}$ што значи да се H₀ прихвата/ [✓ не прихвата]

пр може бити додатно питање ако узмемо нормалну $\mathcal{N}(m, 1.4)$ расподелу шта ће се десити $s=1$

онда морамо водити рачуна да је број степени слободе ⓚ-①-ⓢ – број параметара које смо оценили

↓ број интервала −1

3. Посматрајмо висину напојнице (tip), износ рачуна (Bill) и број особа за столом (size)

a) Једначина регресије која илуструје линеарну зависност висине напојнице од укупног износа рачуна и броја особа за столом дата је са:

$$tip = 0,65597 + 0,9526 \cdot Bill + 0,17815 \cdot size$$

	estimate
(intercept)	0,65597
Bill	0,9526
size	0,17815

б) Ако је укупан рачун износио 35$ за сто за којим су седеле четири особе, колико очекујемо да ће бити висина дате напојнице? 4,702683

c) Подешени коефицијент детерминације је 0,4729 ← adjusted R-squared: 0,4729

d) p-вредност добијеног линеарног модела је $2,2 \cdot 10^{-16}$. Да ли је добијени модел значајан?

ДА ← јако мала p-вредност

```
model ← lm(tip~Bill+size, data=podaci)
summary(model)
lm(tip~Bill+size, data=podaci)$coefficients%*%c(1,35,4) ← предикција (б)
```

*** - Сви коеф. су статистички значајни

→ да неки није био статистички значајан онда бисмо могли да правимо модел 2 који би имао тај један предиктор мање те да упоређујемо 2 модела → то СВЕ МОЖЕ БИТИ НА ТЕСТУ

(овде је био такав пример да то све није било смисла радити) ***

*** → имаћемо 3 задатка

1. зад ће увек бити неки од парам. тестова
2. зад ће бити неки од непараметарских тестова
3. зад ће бити ANOVA или регресија - зависи од групе (једни ће имати једно, други ће имати друго) ***

*** → за задатке за други колоквијум - долази све што смо радили, сигурно ће бити тачкасте оцене параметара и све што смо радили у R-у пешке да се рачуна (неке компликоване ствари не типа онај километарски рачун за ANOVU → неке једноставније ствари које има смисла да радимо пешке)

- пр. упарени t-test је лаган јер се своди на обичан t-test за један узорак
- онај за два узорка | мало су биле незгодне статистике па то врв. нећемо добити
- али долазе те ствари које се једноставније раде
  - KS тест
  - хи квадрат тест
  - табела контингенције
  - линеарна регресија али само једнострука, само за лин. регресију најмањих квадрата ***