Verovatnoća i Statistika

Softversko inženjerstvo i informacione tehnologije

Inženjerstvo informacionih sistema

školska 2025/26

Pokretanje R-a

1. Napraviti svoj folder sa oznakom XXNNYY, gde je XX oznaka smera (SV/IT), NN broj indeksa (7→07) i YY godina upisa (2021→21)
2. Kopirati ikonu R-a u svoj folder
3. Podesiti Properties kopirane ikone: u Start In uneti punu putanju do svog foldera (na primer c:\Users\Desktop\SV0021)
4. Pokrenuti R
5. Isprobati u komandnom promptu

   ```
   x<-sin(1)
   q()
   ```

   Save Workspace Image: Yes
   (biće sačuvano u fajlu .RData, istorija komandi u .Rhistory)
6. Ponovo pokrenuti R

   ```
   objects()
   x                #treba da je  x = 0.841471
   ```

Normalna raspodela

1. Slučajna promenljiva Z ima normalnu $\mathcal{N}(0,1)$ raspodelu. Izračunati verovatnoću

   a) $P(Z < 1.645) = \phi(1.645)$

   pnorm(1.645)

   b) $P(Z > -1.645) = 1 - \phi(-1.645)$

   1−**pnorm**(−1.645)

   c) $P(|Z| < 1.645) = 2\phi(1.645) - 1$

   2∗**pnorm**(1.645)−1

   d) $P(|Z| > 1.96) = 2 - 2\phi(1.96)$

   2−2∗**pnorm**(1.96)

2. Slučajna promenljiva X ima normalnu $\mathcal{N}(1.5,2.5)$ raspodelu. Izračunati verovatnoću

a) $P(X < 1.645) = \phi\left(\frac{1.645 - 1.5}{2.5}\right)$

pnorm(1.645,1.5,2.5) *#pnorm((1.645−1.5)/2.5)*

b) $P(X > -1.645) = 1 - \phi\left(\frac{-1.645 - 1.5}{2.5}\right)$

1−**pnorm**(−1.645,1.5,2.5)

c) $P(|X| < 1.645) = \phi\left(\frac{1.645 - 1.5}{2.5}\right) - \phi\left(\frac{-1.645 - 1.5}{2.5}\right)$

pnorm(1.645,1.5,2.5)−**pnorm**(−1.645,1.5,2.5)

d) $P(|X| > 1.96) = 1 - \phi\left(\frac{1.96 - 1.5}{2.5}\right) + \phi\left(\frac{-1.96 - 1.5}{2.5}\right)$

1−**pnorm**(1.96,1.5,2.5)+**pnorm**(−1.96,1.5,2.5)

3. Slučajna promenljiva Z ima normalnu $\mathcal{N}(0,1)$ raspodelu. Naći z za koje je

   a) $P(Z < z) = 0.9$

   qnorm(0.9)

   b) $P(Z > z) = 0.95$

   $\Rightarrow P(Z \leq z) = 0.05$

   qnorm(0.05)

   c) $P(|Z| < z) = 0.95$

   $P(|Z| < z) = 2\phi(z) - 1 \quad \Rightarrow \quad \phi(z) = 0.975$

   qnorm(0.975)

4. Slučajna promenljiva X ima normalnu $\mathcal{N}(1.5,2.5)$ raspodelu. Naći x za koje je

   a) $P(X < x) = 0.9$

   qnorm(0.9)∗2.5+1.5

   b) $P(X > x) = 0.95$

   qnorm(0.05)∗2.5+1.5

5. Slučajna promenljiva Z ima normalnu $\mathcal{N}(0,1)$ raspodelu. Neka je $X = Z^2$.

   a) Izračunati verovatnoću $P(X < 2.25)$

   $\Rightarrow X : \chi^2_1$

   pchisq(2.25,1)

   b) Odrediti x za koje je $P(X > x) = 0.95$.

   $P(X \leq x) = 0.05$

   qchisq(0.05,1)

Podsetnik: Neka su $Z_1, Z_2, \ldots, Z_n$ nezavisne slučajne promenljive za koje važi $Z_i : \mathcal{N}(0,1)$, za svako $i = 1,2,\ldots,n$. Tada slučajna promenljiva

$$X = \sum_{i=1}^{n} Z_i^2$$

ima Pirsonovu χ^2_n raspodelu.

Granične teoreme

5. Novčić se baca 40 puta.

   a) Odrediti tačnu verovatnoću da će biti barem 22 grba.

      1−**pbinom**(21,40,.5)

   c) Koristeći aproksimaciju Poasonovom raspodelom oceniti verovatnoću da će biti barem 22 grba.

      1−**ppois**(21,40∗.5)

2. Nezavisne slučajne promenljive $X_1, X_2, \ldots, X_{30}$ imaju istu uniformnu raspodelu $\mathcal{U}(0,1)$. Simulacijom u R-u približno odrediti verovatnoću $P\left(\sum_{i=1}^{30} X_i < 17\right)$.

```
n<−10000
s<−numeric(n)
for(k in 1:n){s[k]<−sum(runif(30))<17}
p<−mean(s)
```

$p \approx 0.89$

Deskriptivna statistika

1. Neka je dat uzorak

87	103	130	160	180	195	132	145	211	105
145	153	152	138	87	99	93	119	129	145

a) Odrediti modus i medijanu.

Poređamo vrednosti iz uzorka u varijacioni niz (neopadajući niz).

87 87 93 99 103 105 119 129 130 <u>132 138</u> 145 145 145 152 153 160 180 195 211

Modus je vrednost sa najvećom frekvencijom, tj. sa najvećim brojem pojavljivanja u uzorku. Medijana je vrednost koja se nalazi u sredini uzorka i koja ga deli na dva jednaka dela.

$Mo = 145$ i $Me = \frac{132+138}{2} = 135$ $\left(\frac{x_{n/2}+x_{n/2+1}}{2} \text{ za } n \text{ parno}, \; x_{\frac{n+1}{2}} \text{ za } n \text{ neparno}\right)$

```
x<-c(87,103,130,160,180,195,132,145,211,105,145,153,152,138,87,99,93,119,129,145)
Me<-median(x)                                  #medijana
tx<-table(x)                                   #tabela frekvencija
Mo<-as.numeric(names(tx)[which.max(tx)])       # ispisuje samo najmanji modus
Mo<-as.numeric(names(tx)[tx==max(tx)])         # ispisuje sve moduse
```

b) Izračunati aritmetičku sredinu i standardnu devijaciju uzorka.

Aritmetička sredina uzorka: $\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$

Uzoračka disperzija: $\overline{S}_n^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2$, Standardna devijacija: $\overline{S}_n = \sqrt{\overline{S}_n^2}$

Popravljena (korigovana) uzoračka disperzija: $\overline{S}_n'^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2 = \frac{n}{n-1}\ \overline{S}_n^2$

$\Rightarrow \overline{S}_n^2 = \frac{n-1}{n}\ \overline{S}_n'^2$

$\overline{x}_{20} = \frac{87+103+130+\cdots+145}{20} = 135.4$, $\overline{s}_{20} = \sqrt{\frac{(87-135.4)^2+(103-135.4)^2+\cdots+(145-135.4)^2}{20}} = 33.81$

```
xn<-mean(x)                    #aritmeticka sredina
n<-length(x)
sn2<-sd(x)^2*(n-1)/n           #uzoracka disperzija
sn<-sqrt(sd(x)^2*(n-1)/n)      #standardna devijacija
#var(x)=sd(x)^2
```

c) Odrediti koeficijent spljoštenosti i koeficijent asimetrije.

Momenat reda k: $M_k = \frac{1}{n}\sum_{i=1}^{n} X_i^k$ $\qquad (M_1 = \overline{X}_n)$

Centralni momenat reda k: $\mu_k = \frac{1}{n}\sum_{i=1}^{n} (X_i - \overline{X}_n)^k$ $\qquad (\mu_2 = \overline{S}_n^2)$

Koeficijenti spljoštenosti i asimetrije su pokazatelji oblika raspodele.

Koeficijent spljoštenosti (*kurtosis*): $K_s = \frac{\mu_4}{\mu_2^2}$, koeficijent asimetrije (*skewness*): $K_a = \frac{\mu_3}{\mu_2^{3/2}}$

```
mi4<-mean((x-xn)^4)          #centralni momenat 4. reda
m4<-mean(x^4)                #(obican) momenat 4. reda

mi3<-mean((x-xn)^3)
mi2<-mean((x-xn)^2)

Ks<-mi4/mi2^2
Ka<-mi3/mi2^(3/2)
```

Koeficijent spljoštenosti: $K_s = 2.594 \rightarrow$ raspodela je spljoštena u odnosu na normalnu

Koeficijent asimetrije: $K_a = 0.442 \rightarrow$ raspodela je asimetrična u desno

Napomena: Pored funkcija koje su ugrađene u R, postoji veliki broj dodatnih funkcija koje se mogu pronaći u okviru paketa. Paket **e1071**[*] sadrži funkcije **kurtosis** i **skewness** koje možemo iskoristiti za izračunavanje koeficijenta spljoštenosti i koeficijenta asimetrije.

```
install.packages("e1071")
library(e1071)

moment(x, order=5)                  #(obican) momenat 5. reda
moment(x, order=5, center=TRUE)     #centralni momenat 5. reda

kurtosis(x,type=1)+3                # koeficijent   spljostenosti
skewness(x,type=1)                  # koeficijent   asimetrije
```

Primetimo da vrednost koju dobijamo naredbom **kurtosis(x,type=1)** iznosi -0.406 i da se ova vrednost ne poklapa se sa vrednošću 2.594 koju smo dobili za koeficijent spljoštenosti. Razlog leži u činjenici da se u određenim knjigama uzima da je koeficijent spljoštenosti za normalnu $\mathcal{N}(0,1)$ raspodelu 0, a ne 3 kao što smo izveli na vežbama. Iz tog razloga moramo dodati 3, da bismo dobili istu vrednost kao kada radimo "peške".

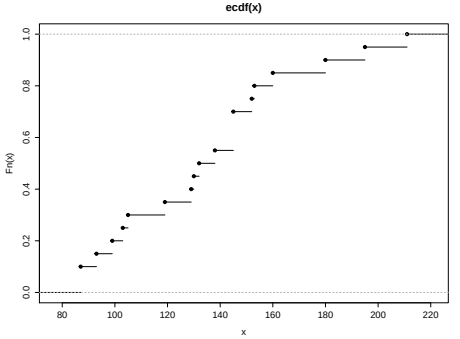
[*]Od verzije 4.3.3 (29.2.2024.), funkcije iz paketa e1071 su ugrađene kao redovne funkcije.

d) Nacrtati uzoračku funkciju raspodele.

Uzoračka (empirijska) funkcija raspodele $F_n^* = \frac{N_x}{n}$

- N_x broj elemenata uzorka koji su $\leq x$
- n obim realizovanog uzorka

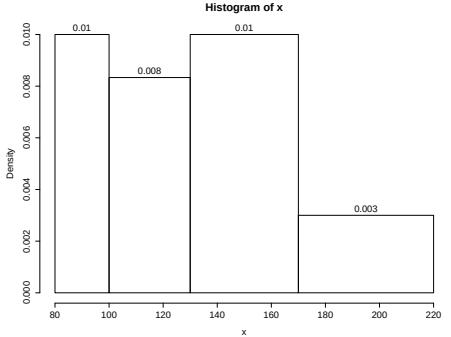
plot.ecdf(x)	*#empirical cumulative distribution function*
table(x)/n	*#verovatnoce da se x nalazi u intervalu*
cumsum(**table**(x))/n	*#vrednosti empirijske funkcije raspodele*



Domaći: Pronaći kako radi funkcija **ecdf**.

e) Nacrtati histogram i poligon.

```
hist(x)                                          #visine pravougaonika odgovaraju frekvencijama
mi<-c(80,100,130,170,220)
hist(x,breaks=mi,probability=TRUE,labels=TRUE)   #histogram gustine
#poligon rucno docrtamo
```



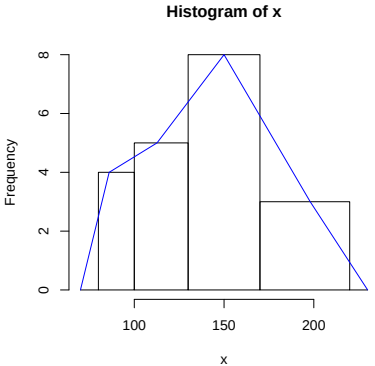
Kod histograma gustine ukupna površina svih pravougaonika iznosi 1.

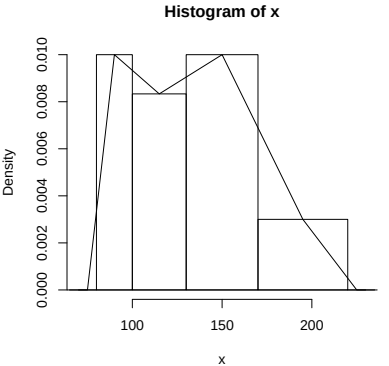
Napomena: Naredbom **hist** se dobija histogram kod kog visine pravougaonika odgovaraju frekvencijama f_i, umesto vrednostima $\frac{f_i}{h_i}$, gde je h_i širina intervala. U okviru paketa **ggplot2** postoje funkcije pomoću kojih se može nacrtati histogram koji odgovara histogramu koji je definisan na predavanjima.

Za radoznale: crtanje poligona u R-u

```
h1<-hist(x,breaks=c(70,mi,230),probability=FALSE)
par(new=TRUE)
plot(h1$mids, h1$counts, type="l", col="blue", axes=FALSE, xlab="", ylab="")

library(agricolae)
h2<-hist(x,breaks=c(70,mi,230),probability=TRUE)
polygon.freq(h2,frequency = 3)                    #frequency=1 za histogram frekvencija
```





f) Odrediti kvartile i IQR.

Za slučajnu promenljivu X kvantil reda $p \in (0,1)$ je vrednost x_p za koju važi

$$P(X < x_p) = p$$

Vidimo da je $100p$ % elemenata u uzorku manje od x_p, a $100(1-p)$ % je veće od x_p.

$\Rightarrow$ $M_e =$ kvantil reda 0.5

Kvartili $\rightarrow$ 25 %

$Q_1 = x_{0.25}$, $Q_2 = Me = x_{0.5}$, $Q_3 = x_{0.75}$ $\quad (Q_1 = 104.5,\ Q_2 = 135,\ Q_3 = 152.2)$

Interkvatrilni razmak IQR = mera rasutosti uzorka
$IQR = Q_3 - Q_1 = 47.75$

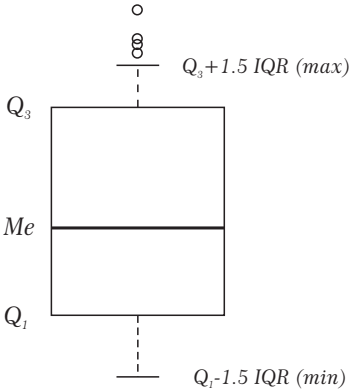
```
summary(x)          #vraca vrednosti za min, Q1, Me=Q2, Xn, Q3, max
IQR(x)              # interkvartilni razmak

#kvantil proizvoljnog reda p za uzorak x mozemo dobiti naredbom quantile(x,p)
Q1<-quantile(x,.25)
Q2<-median(x)       #quantile(x,.5)
Q3<-quantile(x,.75)
```

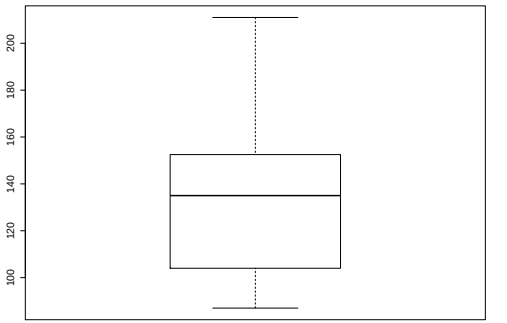
Napomena: decili $\rightarrow$ 10 %, percentili $\rightarrow$ 1 %

g) Nacrtati *Box plot*.

Box plot ima oblik pravougaonika (kutije) sa poklopcima (brkovima)*. Telo *box plot*-a ide od prvog do trećeg kvartila (visina tela je $Q_3 - Q_1 = IQR$). Unutar tela se podebljanom linijom obeležava medijana. Vrednosti koje suviše odstupaju od preostalih se nazivaju *outliers*. To su vrednosti koje su manje od $Q_1 - 1.5\ IQR$ ili veće od $Q_3 + 1.5\ IQR$.



boxplot(x)



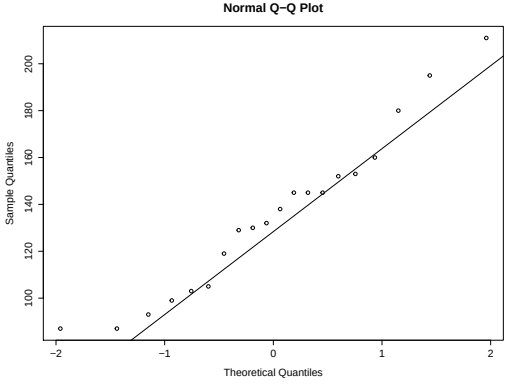
*eng. Box-and-whisker plot

h) Nacrtati *Q-Q plot*.

Q-Q plot (*quantile–quantile plot*) se crta kada grafički želimo da utvrdimo da li se dve raspodele slažu crtanjem kvantila te dve raspodele jednih naspram drugih. Na $y-$osu nanosimo realizovane vrednosti uzorka, a na $x-$osu kvantile pretpostavljene raspodele. Ukoliko se posmatrane raspodele slažu, dobijeni skup tačaka će ležati na pravoj $y = x$.

```
#peske crtanje  QQ plota
qx<-qnorm((1:n)/n)
plot(qx,sort(x))

#pomocu ugradjenih funkcija
qqnorm(x)
qqline(x)
```



2. Neka je dat intervalni uzorak

I_i	[0,1]	(1,2]	(2,3]	(3,5]	(5,10]	(10,20]
f_i	15	11	7	7	6	4

a) Nacrtati uzoračku funkciju raspodele, histogram i poligon.

I_i	[0,1]	(1,2]	(2,3]	(3,5]	(5,10]	(10,20]
f_i	15	11	7	7	6	4
x_i	0.5	1.5	2.5	4	7.5	15
k_i	15	26	33	40	46	50
f_n^*	0.3	0.52	0.66	0.8	0.92	1

```
xi<-c(0.5,1.5,2.5,4,7.5,15)          #sredine intervala
fi<-c(15,11,7,7,6,4)                 #frekvencije
x<-rep(xi,fi)

fn<-cumsum(fi)/sum(fi)               #vrednosti empirijske funkcije raspodele
plot.ecdf(x)
hist(x,breaks=mi,probability=TRUE,labels=TRUE)
```

Ideja za uzorke većeg obima

```
mi<-c(0,1,2,3,5,10,20)          #deobne tacke

ml<-mi[1:length(mi)-1]          #leve granice intervala
md<-mi[2:length(mi)]            #desne granice intervala

xi<-(ml+md)/2                   #sredine intervala
fi<-c(15,11,7,7,6,4)
x<-rep(xi,fi)
```

Napomena: Obim intervalnog uzorka dobijamo sabiranjem frekvencija svih intervala. Pored frekvencija intervala, računaju se i relativne i kumulativne frekvencije. Relativne frekvencije se dobijaju deljenjem pojedinačnih frekvencija intervala sa obimom uzorka. Kumulativne frekvencije dobijamo sabiranjem frekvencije posmatranog intervala sa frekvencijama svih prethodnih intervala, tj. sa kumulativnom frekvencijom prethodnog intervala.

```
sum(fi)                         #obim uzorka
fi/sum(fi)                      #relativne frekvencije
cumsum(fi)                      #kumulativne frekvencije
```

* Relativne frekvencije se kod običnog uzorka mogu dobiti i pomoću naredbe:

prop.table(table(uzorak))

b) Odrediti modus i medijanu.

Kod intervalnog uzorka postoje posebne formule za računanje modusa i medijane:

$$M_o = m_{s-1} + h_s \frac{r_1}{r_1 + r_2} = 0 + 1 \cdot \frac{15}{15+4} = 0.7895$$

- $I_s = (m_{s-1}, m_s)$ modalni interval (interval sa najvećom frekvencijom) $\rightarrow$ $[0,1]$
- h_s širina modalnog intervala
- $r_1 = f_s - f_{s-1}$
- $r_2 = f_s - f_{s+1}$

$$M_e = m_{l-1} + h_l \frac{\frac{n}{2} - k_{l-1}}{f_l} = 1 + 1 \cdot \frac{25-15}{11} = 0.90909$$

- $I_l = (m_{l-1}, m_l)$ medijalni interval
  (interval sa najmanjom kumulativnom frekvencijom većom od $\frac{n}{2}$) $\rightarrow$ $(1,2]$
- h_l širina medijalnog intervala
- k_{l-1} kumulativna frekvencija intervala koji prethodi medijalnom
- f_l frekvencija medijalnog intervala

c) Izračunati aritmetičku sredinu i uzoračku disperziju.

```
xn<-mean(x)
n<-length(x)
sn2<-sd(x)^2*(n-1)/n
```

d) Odrediti koeficijent spljoštenosti i koeficijent asimetrije.

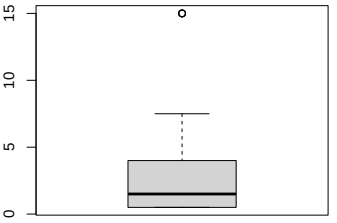
```
mi4<-mean((x-xn)^4)
mi3<-mean((x-xn)^3)
mi2<-mean((x-xn)^2)
Ks<-mi4/mi2^2
Ka<-mi3/mi2^(3/2)
```

e) Naći kvartile i nacrtati *Q-Q plot*.

```
Q1<-quantile(x,.25)
Q2<-median(x)
Q3<-quantile(x,.75)
IQR(x)
qqnorm(x)
qqline(x)
```

f) Nacrtati *Box plot* i odrediti *outlier*-e.

```
boxplot(x)
x[x<Q1−1.5∗IQR(x) | x>Q3+1.5∗IQR(x)]        # outlieri
```



Domaći rad

Na slučajan način odabrati neke od prvih zadataka iz profesorove zbirke ("Zbirka rešenih zadataka iz verovatnoće i statistike") i kompletno ih rešiti peške* i u R-u. (Poželjno je uraditi jedan zadatak sa običnim uzorkom, jedan sa intervalnim uzorkom i zadatak 144.)

*Nacrtati histogram, boxplot i empirijsku funkciju raspodele bez upotrebe računara

Domaći rad

U posebnom script fajlu napisati funkciju koja za prosleđen uzorak ispisuje deskriptivnu statistiku.

Na primer:

deskstat.R

```
deskstat<-function(x){
  n<-length(x)
  print(paste0("Obim␣uzorka:", n))

   ...              #deskriptivna  statistika  kao u prethodnim zadacima

  boxplot(x)
}
```

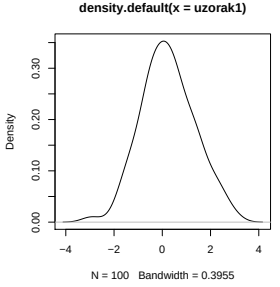
Pronaći kako da se funkciji doda opcioni vektor sa zadatim deobnim tačkama za crtanje histograma i implementirati to u napisanu funkciju.

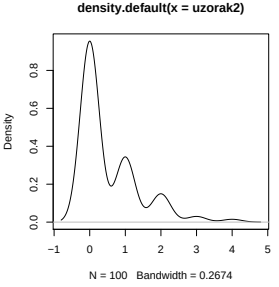
3. Posmatraju se dva uzorka obima 100. Prvi uzorak čine brojevi sa $\mathcal{N}(0,1)$ raspodelom (zaokruženi na 2 decimale), a u drugom uzorku su brojevi sa $\mathcal{P}(0.5)$ raspodelom. (Postaviti da "seme" za oba uzorka bude 1111.)

```
set.seed(1111)
uzorak1<-round(rnorm(100),digits=2)
uzorak2<-rpois(100,lambda=.5)
```

a) Nacrtati grafik funkcije gustine za svaki od ova dva uzorka.

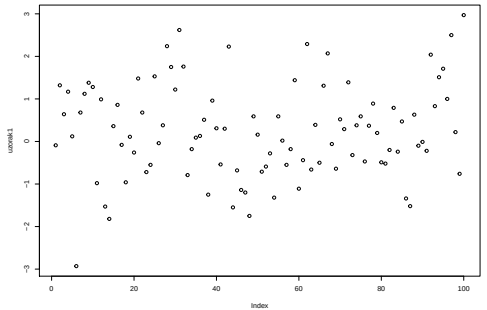
```
plot(density(uzorak1))
plot(density(uzorak2))
```

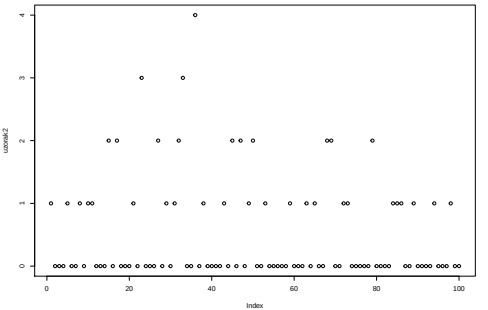




b) Nacrtati dijagram rasipanja (*scatterplot*).

```
plot(uzorak1)
plot(uzorak2)
```



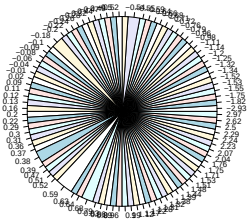


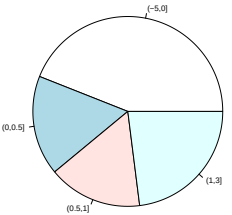
Napomena: Umesto kružićima, tačke na grafiku mogu biti označene i nekim drugim simbolom, npr. **plot**(uzorak1,pch=3).

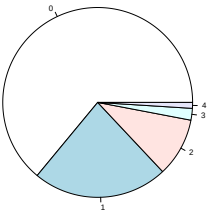


c) Nacrtati kružni dijagram, tj. pitu (*pie chart*).

```
pie(table(uzorak1))
x<-cut(uzorak1,breaks=c(-5,0,.5,1,3))        #element uzorka menjamo odgovarajucim intervalom
table(x)
pie(table(x))
pie(table(uzorak2))
```

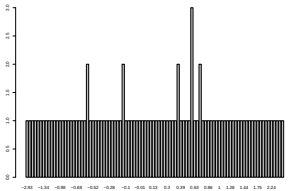


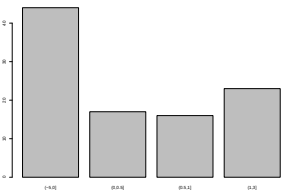


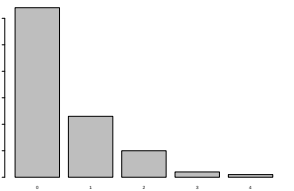


d) Nacrtati stubičasti dijagram (*bar chart*).

```
barplot(table(uzorak1))
barplot(table(x))                    #ponovo je preglednije gledati intervale za prvi uzorak
barplot(table(uzorak2))
#barplot(table(uzorak2),col="cyan")
```







Domaći rad

Koja je razlika između histograma i barplota?

e) Izračunati uzorački koeficijent korelacije i kovarijansu.

Kovarijansa: $cov(x,y) = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x}_n)(y_i - \overline{y}_n)$

Koeficijent korelacije: $r = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i-\overline{x}_n)(y_i-\overline{y}_n)}{\sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i-\overline{x}_n)^2}\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i-\overline{y}_n)^2}} = \frac{\sum_{i=1}^{n}(x_i-\overline{x}_n)(y_i-\overline{y}_n)}{\sqrt{\sum_{i=1}^{n}(x_i-\overline{x}_n)^2}\sqrt{\sum_{i=1}^{n}(y_i-\overline{y}_n)^2}}$

```
cor(uzorak1,uzorak2)                    #korelacija
cov(uzorak1,uzorak2)                    #kovarijansa

#cor(uzorak1,uzorak2) = cov(uzorak1,uzorak2) /sd(uzorak1) /sd(uzorak2)
```

f) Odrediti kvantile reda 0.05, 0.1, 0.15, 0.2 ...,0.9 ,0.95, 1 za prvi uzorak. Naći standardizovane vrednosti prvog uzorka, tzv. $z - score$.

$z_i = \frac{x_i - m}{\sigma}$

$z - score$ predstavlja odstupanje vrednosti obeležja od srednje vrednosti u odnosu na standardnu devijaciju

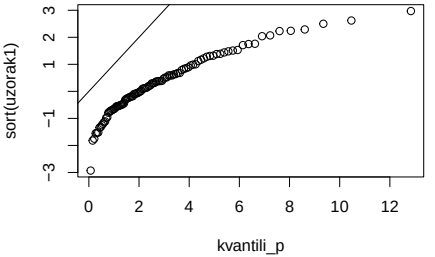
```
quantile(uzorak1, probs=seq(0,1,0.05))    #kvantili za uzorak1
scale(uzorak1)                            #z-score za uzorak1
(uzorak1-mean(uzorak1))/sd(uzorak1)       #peske z-score
```

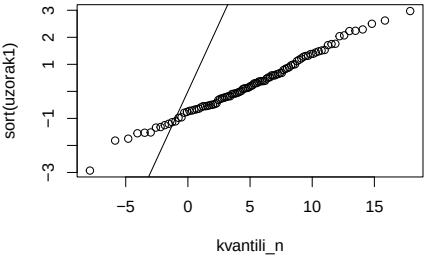
g) Nacrtati *Q-Q plot* sa kvantilima Pirsonove χ^2_3 i Normalne $\mathcal{N}(5,5)$ raspodele.

Za $\mathcal{N}(0,1)$ raspodelu postoji ugrađena funkcija **qqnorm** za crtanje *Q-Q plot-a,* dok za ostale raspodele moramo peške da crtamo.

```
kvantili_p<-qchisq(ppoints(100),df=3)    #kvantili Pirsonove raspodele
qqplot(kvantili_p,sort(uzorak1))
abline(a=0,b=1)                          #prava y=x

kvantili_n<-qnorm(ppoints(100),5,5)      #kvantili N(5,5) raspodele
qqplot(kvantili_n,sort(uzorak1))
abline(a=0,b=1)
```





Unos podataka i NA vrednosti

Prilikom popunjavanja neke ankete, moguće je da dođe do slučajnih grešaka u unosu. Na primer, umesto 30 godina greškom je uneto 300 ili -30. Ovakve greške mogu da dovedu do nereprezentativnih numeričkih vrednosti koje opisuju posmatrani uzorak i zbog toga se uglavnom određeni procenat ekstremnih vrednosti izuzima iz razmatranja.

Takođe, moguće je da su neka polja u anketi ostala nepopunjena. Takva polja u R-u dobijaju NA vrednost (*Not Available*).

```
x<-scan()                          #pojedinacni rucni unos

y<-c(30,-15,42,61,19,38,490,57)    #npr. broj godina ispitanika
data.entry(y)                      #pojedinacna izmena

mean(y)                            #nije ocekivano da je prosecan broj godina slucajnih ispitanika 90.25
mean(y,trim=0.2)                   #odseca po 20% vrednosti sa obe strane pre izracunavanja

y<-c(y,NA)
mean(y)                            #javlja gresku
mean(y,na.rm=T)                    #pravilno
mean(y[!is.na(y)])                 #pravilno
mean(na.omit(data.frame(y)$y))     #izbegavati posto brise cele vrste
```

Grupisanje podataka

```
x<-c(1,2,4,5,1,9,9,1)
y<-c(rep("a",4),rep("b",3),"c")

#losa ideja:
Dc<-cbind(x,y)          #"spajanje" vektora u matricu po kolonama/vrstama
Dr<-rbind(x,y)          #korekcija tipova podataka

#bolja ideja:
D<-data.frame(x,y)      #data frame moze da sadrzi kolone razlicitih tipova, za razliku od matrica
D<-data.frame(Brojevi=x,Slova=y)

D$Brojevi[7]=2          #izmena vrednosti
D$Brojevi==2            #upit o vrednosti
D[D$Brojevi==2, ]       #selekcija vrsta po kriterijumu

#alternativno:
subset(D,D$Brojevi==2)

D$Brojevi[D$Slova=="a"] = D$Brojevi[D$Slova=="a"] * 2
```

Faktori

Atributivna (kategorijalna) obeležja (npr. boja očiju, pol, krvna grupa) se u R-u mogu uneti kao vektori sa stringovima, ali je bolje takva obeležja uneti kao faktor.

```
gender<-factor(c("male", "female", "female", "male"))
typeof(gender)
attributes(gender)
as.character(gender)

f.pomocni<-c(rep("a",4),rep("b",6),rep("c",2))
f<-rep(f.pomocni,length=100)                    #f ima 100 elemenata
f<-as.factor(f)                                 #nivoi faktora: a, b, c

y<-round(rnorm(100),digits=2)
z<-rpois(100,lambda=.5)

D<-data.frame(f,y,z)

D$y[D$f=="a"]
D[D$f='a', ]                                    #navodnici ili apostrofi
D[D$f=="a" & D$z==0, ]

write.csv(D, file ="frame.csv")  #upisivanje u csv fajl
#write.csv(D, file ="frame.csv",row.names=FALSE)
```

Manipulacija podacima

Pokretanje skript fajla iz R-a:

```
setwd("c:/Users/Desktop/SV0021")
source("zadatak1.R")
```

Proveru putanje do radnog direktorijuma možemo izvršiti naredbom **getwd**().

Napomena: Ukoliko se putanja ne poklapa sa željenom, treba iskopirati željenu putanju i zatim u kopiranoj putanji izmeniti \ u / na svim mestima.

Čuvanje promenljivih

```
load(".RData")                          #ucitavanje promenljivih iz R formata
save.image("novo.RData")                #cuvanje Work space u fajl novo.RData
rm(list=ls())                           #oslobadjanje svih promenljivih
load("novo.RData")
save(xn,sn, file ="xnsn.rda")           #cuvanje promenljivih xn i sn u fajl xnsn.rda
```

Napomena: Određenu promenljivu možemo osloboditi sa **rm**(x).

Učitavanje csv tabele u R-u

```
FlightDelays<-read.csv("FlightDelays.csv")      #ucitavanje csv tabele

View(FlightDelays)                              #prikaz ucitanih podataka
FlightDelays<-edit(FlightDelays)                #otvaranje data editora

summary(FlightDelays)                           #osnovna deskriptivna statistika
 str (FlightDelays)                             #vraca strukturu podataka
names(FlightDelays)                             #vraca nazive promenljivih iz tabele

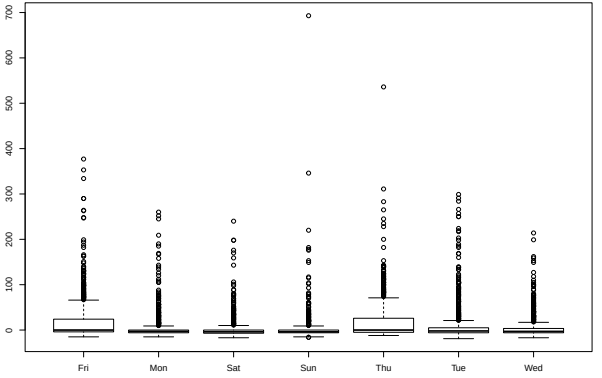
head(FlightDelays)                              # ispisuje prvih 6 redova
head(FlightDelays,n=10)                         #prvih 10 redova
head(FlightDelays,n=-10)                        #svi redovi osim poslednjih 10
 tail (FlightDelays)                            #poslednjih 6 redova

FlightDelays[1:10,1:3]                          #prvih 10 redova, prve 3 kolone
FlightDelays[1:10,c(1,3,7)]                     #prvih 10 redova, kolone 1, 3 i 7
```

4. Izdvojiti iz kolone Delay vrednosti koje se odnose na ponedeljak i nacrtati *Box plot* za Delay po danima.

```
delay<-FlightDelays$Delay                  #sa $ se pristupa podelementu
indeks<-FlightDelays$Day=="Mon"            #u vektor indeks upisuje TRUE ako je ponedeljak
delaymon<-delay[indeks]                    #izdvaja vrednosti za koje je indeks TRUE

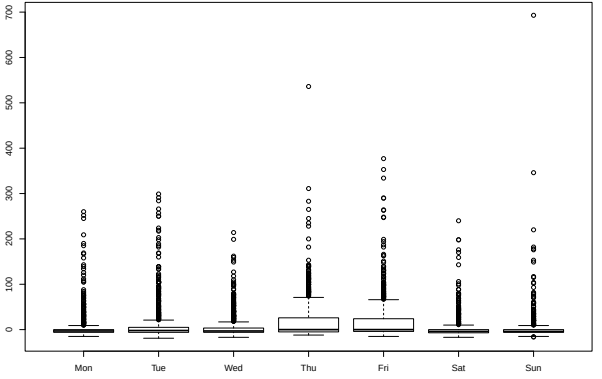
boxplot(Delay~Day,data=FlightDelays)       #boxplot po danima
```



Napomena: Primetimo da su boxplot-ovi sortirani po abecedi. Više bismo voleli da je sortiranje izvršeno po danima u nedelji. To možemo uraditi pomoću faktora.

```
FlightDelays$Day <- factor(FlightDelays$Day, levels = c("Mon","Tue","Wed","Thu","Fri","Sat","Sun"))
summary(FlightDelays)                    #obratiti paznju sta sada pise za kolonu Day

boxplot(Delay~Day,data=FlightDelays)
```

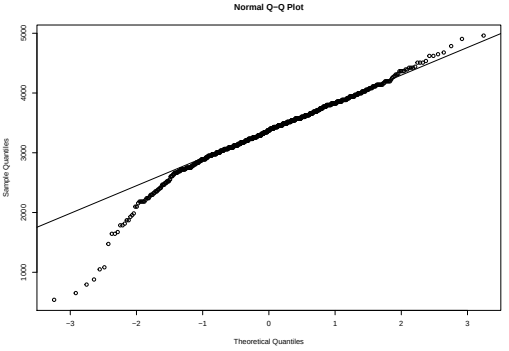


5. Učitati iz fajla TXBirths2004.csv kolonu Weight samo za dečake i napraviti deskriptivnu statistiku.

```
podaci<-read.csv("TXBirths2004.csv")

indeks<-podaci$Gender=="Male"
weightMale<-podaci$Weight[indeks]

source("deskstat.R")
deskstat(weightMale)
```



Na osnovu dobijenog *Q-Q plot*-a zaključujemo da postoji mogućnost da posmatrani uzorak ima normalnu raspodelu. Međutim, ovo ne možemo tvrditi sa sigurnošću. Zato je neophodno sprovesti odgovarajuće statističke testove koji će dati odgovor na ovo pitanje.

6. Napraviti deskriptivnu statistiku za kolonu AveKW iz fajla Turbine.csv za mesece april i jun.

```
podaci<-read.csv("Turbine.csv")

indeks<-substr(podaci$Date2010,1,3)=="Apr" | substr(podaci$Date2010,1,3)=="Jun"
podaciAprJun<-podaci$AveKW[indeks]

source("deskstat.R")
deskstat(podaciAprJun)
```

Domaći rad

Pronaći kako se u R-u zapisuju logički operatori $\neq$, $\wedge$, $\neg$.

7. Napraviti tablicu Gausove raspodele (zbirka, str. 169).

```
p<−pnorm(seq(from=0, by=0.01, length=350))
dim(p)<−c(10,35)
p<−t(p)    #transponovanje
View(round(p,digits=4))

#2. nacin
P<−pnorm(seq(from=0, by=0.01, length=350))
P<−matrix(P,35,10,byrow=TRUE)
View(round(P,digits=4))
```

8. Napraviti tablicu Studentove raspodele (zbirka, str. 170).

```
df<−c(1:30,40,60,120,Inf)
p<−c(.75,.9,.95,.975,.99,.995,.9995)
q<−t(outer(p,df,"qt"))
View(round(q,digits=3))
```

Domaći rad

Napraviti tablicu Pirsonove χ^2 raspodele (zbirka, str. 171).

Domaći rad

1. Na slučajan način je izabrano 150 prirodnih brojeva manjih od 1000.

   a) Formirati raspodelu frekvencija sa 10 klasa iste širine i rezultate predstaviti tabelarno.

   b) Odrediti modalni i medijalni interval iz a).

   c) Odrediti aritmetičku sredinu i uzoračku disperziju uzorka.

   d) Odrediti koeficijent asimetrije (skewness) i sedmi centralni momenat uzorka.

   e) Izračunati realizovanu vrednost empirijske funkcije raspodele $f_n^*(615.5)$.

   f) Nactrati histogram i *pie chart* koristeći intervale iz a).

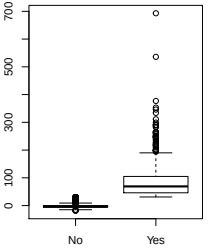
2. Učitati fajl FlightDelays.csv.

   a) Nacrtati *Box plot* za dužinu leta (FlightLength) po mesecu.

   b) Odrediti koliko su u proseku kasnili letovi (Delay) za Denver (Destination: DEN).

   c) Da li je standardna devijacija dužine leta veća kod aviona koji su poleteli između 4 i 8 časova (DepartTime: 4-8am) ili kod onih koji su poleteli između 16 i 20 časova (DepartTime: 4-8pm)?

3. Na osnovu *Box plot*–a uzorka zaključiti da li postoje statistički značajne razlike između srednjih vrednosti elemenata uzorka u ove dve grupe. Odgovor obrazložiti.



4. Naći treći decil za raspodele: $\mathcal{B}(10,\frac{3}{4})$, $\mathcal{G}(\frac{1}{10})$, $\mathcal{E}(0.1)$, t_{10}, χ^2_{10}, $\mathcal{N}(15,3)$.

5. Izračunati vrednost funkcije raspodele u tački $x = 7.5$ ako X ima $\mathcal{B}(10,\frac{3}{4})$, $\mathcal{G}(\frac{1}{10})$, $\mathcal{E}(0.1)$, t_{10}, χ^2_{10}, $\mathcal{N}(15,3)$ raspodelu.

6. Izračunati $\Gamma(-\frac{3}{2})$.

7. Pronaći šta vraćaju naredbe **dnorm** i **dbinom**.

8. Instalirati paket **ggplot2** i nacrtati nekoliko deskriptivnih grafika koristeći funkcije iz ovog paketa.

Intervali poverenja i testiranje parametarskih hipoteza

Posmatra se uzorak od 100 slučajnih brojeva iz intervala $(0,1)$ (npr. seme 12345).

1. Naći 90% interval poverenja za procenat brojeva koji su veći od 0.75.
   Granice intervala poverenja za **nepoznatu verovatnoću** p obeležja sa Bernulijevom raspodelom $X:\begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}$ se dobijaju kao nule polinoma $(n^2+z_\beta^2 n)p^2+(-2Kn-z_\beta^2 n)p+K^2$.

```
#interval poverenja za nepoznatu verovatnocu
set.seed(12345)
x<-runif(100)

K<-length(which(x>.75))          #broj uspesnih  realizacija
n<-length(x)                     #obim uzorka
z<-qnorm((.9+1)/2)               #kvantil normalne N(0,1) raspodele

a<-n^2+z^2*n; b<--2*K*n-z^2*n;  c<-K^2
D<-b^2-4*a*c

x1<-(-b-sqrt(D))/(2*a)
x2<-(-b+sqrt(D))/2/a             #umesto /(2*a) mozemo staviti /2/a
```

   Interval poverenja $I_{0.9}=(0.195,0.338)$ (zaokruženo na 3 decimale)

2. Testirati hipotezu da procenat brojeva koji su veći od 0.75 iznosi 0.3, ukoliko je prag značajnosti 5%.

prag značajnosti $\alpha = 0.05 \quad \Rightarrow \quad$ nivo poverenja $\beta = 1 - \alpha = 0.95$

Testiramo nultu hipotezu $H_0(p = 0.3)$ protiv alternativne hipoteze $H_1(p \neq 0.3)$

a) Koristeći interval poverenja rađen na predavanjima.

```
# testiranje hipoteze o nepoznatoj verovatnoci
set.seed(12345)
x<-runif(100)

K<-length(which(x>.75))
n<-length(x)
z<-qnorm((.95+1)/2)

a<-n^2+z^2*n; b<--2*K*n-z^2*n; c<-K^2
D<-b^2-4*a*c

x1<-(-b-sqrt(D))/2/a
x2<-(-b+sqrt(D))/2/a
```

$p_0 = 0.3 \in I_{0.95} = (0.184047, 0.3537099) \quad \Rightarrow$ hipoteza H_0 se prihvata

b) Koristeći interval poverenja iz zbirke (str. 128).

$I = \left(p - z_\beta \sqrt{\frac{pq}{n-1}}, p + z_\beta \sqrt{\frac{pq}{n-1}}\right)$, gde je $p = \frac{K}{n}$, $q = 1 - p$

```
p<-K/n
q<-1-p

y1<-p-z*sqrt(p*q/(n-1))
y2<-p+z*sqrt(p*q/(n-1))
```

$p_0 = 0.3 \in I_{0.95} = (0.1735962, 0.3464038) \Rightarrow$ hipoteza H_0 se prihvata

Napomena: Interval poverenja rađen na predavanjima je dobijen pomoću Moavr-Laplasove teoreme, dok je interval poverenja dat u zbirci dobijen korišćenjem određenih aproksimacija. Dobijeni intervali poverenja u zadatku pod a) i b) ne predstavljaju prave vrednosti, pošto su dobijeni aproksimacijama. Prave vrednosti za granice intervala poverenja se dobijaju pomoću sledećeg ugrađenog testa u R-u.

c) Koristeći **binom.test** iz R-a.

```
>binom.test(K,n,.3,conf.level=.95)

   Exact binomial test

data: K and n
number of successes = 26, number of trials = 100, p-value = 0.4451
alternative hypothesis: true probability of success is not equal to 0.3
95 percent confidence interval:
 0.1773944 0.3573121
sample estimates:
probability of success
                  0.26
```

$p_0 = 0.3 \in I_{0.95} = (0.1773944, 0.3573121) \Rightarrow$ hipoteza H_0 se prihvata

Domaći rad

Ako smo na nivou poverenja 95% prihvatili određenu nultu hipotezu, šta možemo reći za nivoe poverenja 99% i 90% ?

Učitati fajl prijemni.csv.

3. Naći 90% interval poverenja za srednju vrednost uspeha iz srednje škole (obeležje ima $\mathcal{N}(m,\sigma)$ raspodelu) ako: a) $\sigma = 5$ b) σ nije poznato.

   a) Interval poverenja za **očekivanje** m obeležja $X : \mathcal{N}(m,\sigma)$, σ **poznato:**

$$I = \left(\overline{X}_n - z_\beta \frac{\sigma}{\sqrt{n}}, \overline{X}_n + z_\beta \frac{\sigma}{\sqrt{n}} \right)$$

```
#interval poverenja za ocekivanje m (sigma poznato)
podaci<-read.csv("prijemni.csv")
uspehSkola<-podaci$skola

n<-length(uspehSkola)
xn<-mean(uspehSkola)
sigma<-5
z<-qnorm((1+.9)/2)                    #kvantil normalne N(0,1) raspodele

x1<-xn-z*sigma/sqrt(n)
x2<-xn+z*sigma/sqrt(n)
```

   Interval poverenja $I_{0.9} = (28.23076, 30.86463)$

b) Interval poverenja za **očekivanje** m obeležja $X : \mathcal{N}(m,\sigma)$, gde σ **nije poznato:**

$$I = \left(\overline{X}_n - t_\beta \frac{\overline{S}_n}{\sqrt{n-1}}, \overline{X}_n + t_\beta \frac{\overline{S}_n}{\sqrt{n-1}} \right) = \left(\overline{X}_n - t_\beta \frac{\overline{S}'_n}{\sqrt{n}}, \overline{X}_n + t_\beta \frac{\overline{S}'_n}{\sqrt{n}} \right)$$

```
#interval poverenja za ocekivanje m (sigma nepoznato)
podaci<-read.csv("prijemni.csv")
uspehSkola<-podaci$skola

n<-length(uspehSkola)
xn<-mean(uspehSkola)
s<-sd(uspehSkola)
t<-qt((1+.9)/2,n-1)                    #kvantil Studentove t raspodele

y1<-xn-t*s/sqrt(n)
y2<-xn+t*s/sqrt(n)
```

Interval poverenja $I_{0.9} = (28.1033, 30.99209)$

4. Testirati hipotezu da je srednja vrednost uspeha u srednjoj školi jednaka 32 ($\alpha = 0.05$).

```
# testiranje hipoteze o ocekivanju m (sigma nepoznato)
podaci<-read.csv("prijemni.csv")
uspehSkola<-podaci$skola

n<-length(uspehSkola)
xn<-mean(uspehSkola)
s<-sd(uspehSkola)
t<-qt((1+.95)/2,n-1)

x1<-xn-t*s/sqrt(n)
x2<-xn+t*s/sqrt(n)
```

$H_0(m = 32)$ protiv $H_1(m \neq 32)$

$m_0 = 32 \notin I_{0.95} = (27.81335, 31.28203) \Rightarrow$ hipoteza H_0 se odbacuje

Domaći rad

Ako smo na nivou poverenja 95% odbacili određenu nultu hipotezu, šta možemo reći za nivoe poverenja 90% i 99% ?

5. Naći 95% interval poverenja za varijansu uspeha iz srednje škole.

Interval poverenja za **disperziju** σ^2 obeležja $X : \mathcal{N}(m,\sigma)$: $I = \left(\frac{n\overline{S}_n^2}{y_{\frac{1+\beta}{2}}}, \frac{n\overline{S}_n^2}{y_{\frac{1-\beta}{2}}} \right)$

```
#interval poverenja za varijansu ( disperziju )
podaci<-read.csv("prijemni.csv")
uspehSkola<-podaci$skola

n<-length(uspehSkola)
s<-sd(uspehSkola) ^ 2*(n-1)/n

y1<-qchisq((1+.95)/2,n-1)                    #kvantili Pirsonove raspodele
y2<-qchisq((1-.95)/2,n-1)

x1<-n*s/y1
x2<-n*s/y2
```

Interval poverenja $I_{0.95} = (19.11832, 47.54454)$

Napomena: Interval poverenja za standardnu devijaciju σ : $I = \left(\sqrt{\frac{n\overline{S}_n^2}{y_{\frac{1+\beta}{2}}}}, \sqrt{\frac{n\overline{S}_n^2}{y_{\frac{1-\beta}{2}}}} \right)$

6. Testirati hipotezu o jednakosti srednje vrednosti uspeha na prijemnom kod muških i ženskih kandidata ($\alpha = 0.05$).

   Testiranje hipoteze o jednakosti srednjih vrednosti dva obeležja sa nepoznatim varijansama.

   Nulta hipoteza $H_0(m_1 = m_2)$ protiv alternativne hipoteze $H_1(m_1 \neq m_2)$.

```
# testiranje jednakosti srednjih vrednosti dva nezavisna uzorka
podaci<-read.csv("prijemni.csv")
prijemniM<-podaci$prijemni[podaci$pol=="m"]
prijemniZ<-podaci$prijemni[podaci$pol=="z"]

n1<-length(prijemniM)
n2<-length(prijemniZ)
xn1<-mean(prijemniM)
xn2<-mean(prijemniZ)
```

Ako su varijanse jednake koristi se test statistika

$$T = \frac{\overline{X}_1 - \overline{X}_2}{\sigma\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}},$$

gde je $\sigma = \sqrt{\frac{n_1\overline{S}_1^2 + n_2\overline{S}_2^2}{n_1+n_2-2}}$, koja ima $t_{n_1+n_2-2}$ raspodelu.

```
#jednake varijanse
sn1<-sd(prijemniM)^2*(n1-1)/n1
sn2<-sd(prijemniZ)^2*(n2-1)/n2
sigma<-sqrt((n1*sn1+n2*sn2)/(n1+n2-2))

t0<-(xn1-xn2)/sigma/sqrt(1/n1+1/n2)
t<-qt((1+.95)/2,n1+n2-2)
```

Nulta hipoteza $H_0(m_1 = m_2)$
$t_0 = -1.739699 \in I = (-2.026192, 2.026192) \Rightarrow$ hipoteza H_0 se prihvata

Za različite varijanse koristi se test statistika

$$T = \frac{\overline{X}_1 - \overline{X}_2}{\sqrt{\frac{\overline{S}_1'^2}{n_1} + \frac{\overline{S}_2'^2}{n_2}}},$$

koja približno ima $t_{\min\{n_1-1, n_2-1\}}$ raspodelu.

```
# razlicite  varijanse
s1<-sd(prijemniM)^2
s2<-sd(prijemniZ)^2

t0<-(xn1-xn2)/sqrt(s1/n1+s2/n2)
t<-qt((1+.95)/2,min(n1-1,n2-1))
```

Nulta hipoteza $H_0(m_1 = m_2)$
$t_0 = -1.224453 \in I = (-2.446912, 2.446912) \Rightarrow$ hipoteza H_0 se prihvata

Neparametarski testovi

1. Učitati fajl prijemni.csv i testirati hipotezu da je uspeh u srednjoj školi raspoređen po normalnoj raspodeli ako su grupe za χ^2-test: 10-25, 25-30, 30-35, 35-40 ($\alpha = 0.05$).

   H_0 : broj poena iz srednje škole ima $\mathcal{N}(m,\sigma)$ raspodelu

   Uzorak se grupiše u k intervala (u svakom intervalu imamo najmanje 5 elemenata uzorka).

```
podaci<-read.csv("prijemni.csv")
uspehSkola<-podaci$skola

mi<-c(25,30,35)                          #deobne tacke
 fi <-hist(uspehSkola,c(10,mi,40))$counts #frekvencije
n<-length(uspehSkola)
k<-length(fi)                            #broj intervala
```

   Pošto u $\mathcal{N}(m,\sigma)$ raspodeli imamo dva nepoznata parametra, prvo ih moramo oceniti. Znamo da su centrirani ocenjivači za ove parametre $\hat{m} = \overline{X}_n$ i $\hat{\sigma} = \overline{S}'_n$.

```
s<-2                                     #broj parametara koje treba  oceniti
xn<-mean(uspehSkola)                     #ocena za ocekivanje  m
sn<-sd(uspehSkola)                       #ocena za standardnu devijaciju  sigma
```

```
#funkcija raspodele
Fx<-function(x){
  return(pnorm((x-xn)/sn)                    #pnorm(x,xn,sn)
}

# teorijske verovatnoce
p<-c(Fx(mi),1)-c(0,Fx(mi))                   #sum(p)=1
```

Vektor $p = [p_1, p_2, p_3, p_4]$ sadrži teorijske verovatnoće da se element uzorka nađe u odgovarajućem intervalu, tj.

$p_1 = P(-\infty < X < 25)$, $p_2 = P(25 \leq X < 30)$, $p_3 = P(30 \leq X < 35)$ i $p_4 = P(35 \leq X < \infty)$.

Posmatramo test statistiku $Y = \sum_{i=1}^{k} \frac{(F_i - n\,p_i)^2}{n\,p_i}$, koja ima približno χ^2_{k-1-s} raspodelu.

```
#realizovana vrednost  statistike
y0<-sum((fi-n*p)^2/n/p)

#najveca dozvoljena vrednost  statistike
y<-qchisq(1-.05,k-1-s)
```

$y_0 = 1.296183 < y = 3.841459 \;\Rightarrow$ hipoteza H_0 se prihvata

2. χ^2-testom ispitati saglasnost obeležja čiji je realizovani uzorak (0.12, 0.14, 0.25, 0.05, 0.02, 0.08, 0.03, 0.04, 0.51, 0.07, 0.42, 0.08, 0.33, 0.36, 0.06, 0.23) sa raspodelom:

$$\varphi(x) = \begin{cases} \theta x^{\theta-1}, & x \in [0,1] \\ 0, & x \notin [0,1] \end{cases}, \theta > 0.$$

```
#uzorak
x<-c(0.12,0.14,0.25,0.05,0.02,0.08,0.03,0.04,0.51,0.07,0.42,0.08,0.33,0.36,0.06,0.23)
xs<-sort(x)              #sortiran uzorak
fi<-c(6,5,5)             #frekvencije (sami konstruisemo intervale)
mi<-c(0.07,0.23)         #deobne tacke
n<-sum(fi)               #obim uzorka
k<-length(fi)            #broj intervala
```

Pošto u posmatranoj gustini imamo nepoznati parametar θ, prvo ćemo oceniti parametar metodom momenta. Dobijamo da je $\hat{\theta} = \dfrac{\overline{X}_n}{1-\overline{X}_n}$.

```
xn<-mean(x)
theta<-xn/(1-xn)         #ocena parametra theta
s<-1                     #broj parametara
```

Dalje tražimo funkciju raspodele

$$F(x) = P(X \leq x) = \int_{-\infty}^{x} \varphi(t)\, dt = \begin{cases} 0, & x \leq 0, \\ x^{\theta}, & 0 \leq x < 1, \\ 1, & x \geq 1. \end{cases}$$

```
# teorijske  verovatnoce
p<-c(mi^theta,1)-c(0,mi^theta)

#realizovana vrednost   statistike
y0<-sum((fi-n*p)^2/n/p)

#najveca dozvoljena vrednost   statistike
y<-qchisq(1-.05,k-1-s)
```

H_0 : gustina obeležja je data sa $\varphi(x) = \theta x^{\theta-1}$, $x \in [0,1]$

$y_0 = 3.39369 < y = 3.841459 \ \Rightarrow$ hipoteza H_0 se prihvata

3. Testom Kolmogorov-Smirnov testirati hipotezu o saglasnosti datog uzorka sa normalnom raspodelom $\mathcal{N}(10,4)$ ($\alpha = 0.05$).

$0-5$	$5-15$	$15-20$	$20-30$	$30-40$
3	7	10	15	5

H_0 : posmatrani uzorak ima $\mathcal{N}(10,4)$ raspodelu

Posmatramo test statistiku $\sqrt{n}\,D_n$, gde je $D_n = \sup_x |F_n^*(x) - F(x)|$.

```
fi<-c(3,7,10,15,5)
mi<-c(0,5,15,20,30,40)
ml<-mi[1:length(mi)-1];      md<-mi[2:length(mi)]
xi<-(ml+md)/2                #sredine intervala
f<-cumsum(fi)                #kumulativne frekvencije
n<-sum(fi)

Fn<-f/n                      #empirijska funkcija raspodele
F<-pnorm(xi,10,4)            #data funkcija raspodele

sqrt(n)*max(abs(Fn-F))       #realizovana vrednost statistike
```

$2.970034 > 1.36 = \lambda_{0.95} \;\Rightarrow$ hipoteza H_0 se odbacuje

Napomena: Kolmogorov-Smirnov test se može upotrebiti samo u slučajevima kada imamo POZNATU NEPREKIDNU raspodelu.

4. Ispitati nezavisnost obeležja X i Y čije su realizovane vrednosti uzorka:

5	18	9
6	7	20

Specijalan oblik χ^2 testa koristimo za ispitivanje nezavisnosti dva diskretna obeležja i tada govorimo o **tabelama kontigencije**.

Matrica kontigencije se dobija na sledeći način:

5	18	9	32
6	7	20	33
11	25	29	65

```
#matrica sa frekvencijama
fij <-matrix(c(5,6,18,7,9,20),2,3)

#matrica kontingencije
source("matrica_kontigencije.R")          #videti slajd 61
f<-kont(fij)
#f<-matrix(c(5,6,11,18,7,25,9,20,29,32,33,65),3,4)

#obim uzorka
n<-sum(fij)                               #n<-f[nrow(f),ncol(f)]
```

Ukoliko bi obeležja X i Y bila nezavisna, moralo bi da važi $p_{ij} = p_{i\cdot} \cdot p_{\cdot j} \Leftrightarrow \frac{f_{ij}}{n} = \frac{f_{i\cdot}}{n} \cdot \frac{f_{\cdot j}}{n}$, odakle dobijamo teorijske frekvencije $f'_{ij} = \dfrac{f_{i\cdot} \cdot f_{\cdot j}}{n} = n\, p_{i\cdot}\, p_{\cdot j}$:

$$f'_{11} = \tfrac{32\cdot 11}{65} = 5.415 \quad f'_{12} = \tfrac{32\cdot 25}{65} = 12.308 \quad f'_{13} = \tfrac{32\cdot 29}{65} = 14.277$$

$$f'_{21} = \tfrac{33\cdot 11}{65} = 5.585 \quad f'_{22} = \tfrac{33\cdot 25}{65} = 12.692 \quad f'_{23} = \tfrac{33\cdot 29}{65} = 14.723$$

```
#matrica sa teorijskim frekvencijama
ft <- matrix(NA,nrow(fij),ncol(fij))

for (i in 1:nrow(ft)){
  for (j in 1:ncol(ft)){
    ft[i,j]=f[i,ncol(f)]*f[nrow(f),j]/n
  }
}
```

Posmatramo test statistiku

$$Y = \sum_{i,j} \frac{(F_{ij} - n\, p_{i\cdot}\, p_{\cdot j})^2}{n\, p_{i\cdot}\, p_{\cdot j}} = \sum_{i,j} \frac{(F_{ij} - F'_{ij})^2}{F'_{ij}},$$

koja ima približno χ^2 raspodelu sa $(n_X - 1)(n_Y - 1)$ stepeni slobode.

```
#realizovana vrednost   statistike
y0<-sum((fij-ft)^2/ft)

#najveca dozvoljena vrednost   statistike
y<-qchisq(1-.05,(nrow(fij)-1)*(ncol(fij)-1))
```

H_0 : obeležja X i Y su nezavisna

$y_0 = 9.09009 > y = 5.991465 \;\Rightarrow\;$ hipoteza H_0 se odbacuje.

matrica_kontigencije.R

```
kont <- function(mat){

  m <- nrow(mat)
  n <- ncol(mat)
  res <- matrix(numeric((m+1)*(n+1)), m+1, n+1)

  for (i in 1:m){
    for (j in 1:n){
      res[i, j] <- mat[i,j]
      res[m+1, j] <- res[m+1, j] + mat[i, j]
      res[i, n+1] <- res[i, n+1] + mat[i, j]
    }
  }

  res[m+1, n+1] <- sum(res[m+1, 1:n])

  return(res)

}
```

Domaći rad

Učitati fajl FlightDelays.csv.

1. Naći 90% interval poverenja dužine leta (FlightLength) za ponedeljak (Day: Mon).
2. Testirati hipotezu da je procenat letova koji su kasnili više od 20 minuta jednak 0.2 sa pragom značajnosti 5%.
3. Ispitati da li postoje statistički značajne razlike između srednjih vrednosti kašnjenja letova tokom maja i juna.
4. Testom Kolmogorov-Smirnov testirati hipotezu da uzorak

   $$0.16,\ 0.35,\ 0.86,\ 0.05,\ 0.11,\ 0.07,\ 0.04,\ 0.09,\ 0.52,\ 0.38$$

   ima uniformnu raspodelu $\mathcal{U}(0,1)$.
5. Ispitati nezavisnost obeležja X i Y čije su realizovane vrednosti uzorka:

19	6	12
25	18	16

6. χ^2-testom ispitati saglasnost obeležja čiji je realizovani uzorak

   $$0.62,\ 0.54,\ 0.21,\ 0.48,\ 0.71,\ 0.58,\ 0.32,\ 0.48,\ 0.55,\ 0.38,$$
   $$0.58,\ 0.42,\ 0.52,\ 0.33,\ 0.43,\ 0.23,\ 0.58,\ 0.76,\ 0.53,\ 0.64$$

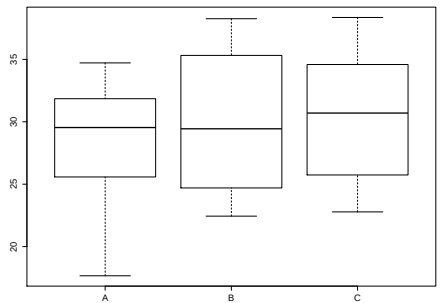
   sa eksponencijalnom raspodelom $\mathcal{E}(\lambda)$. Uzorak podeliti na tri intervala koristeći deobne tačke 0.45 i 0.55.

ANOVA (Analiza varijanse)

Učitati fajl prijemni.csv.

1. Nacrtati *Box plot* uspeha iz srednje škole po grupama.

```
podaci<-read.csv("prijemni.csv")
boxplot(skola~grupa,data=podaci)
#plot(podaci$skola~podaci$grupa)
```



Pitanje: Da li su srednje vrednosti broja poena iz škole jednake u ove tri grupe?

2. Testirati hipotezu o jednakosti srednje vrednosti uspeha iz srednje škole po grupama (ANOVA).

```
>podaci<-read.csv("prijemni.csv")

>anova(lm(skola~grupa,data=podaci))
Analysis of Variance Table

Response: skola
           Df  Sum Sq Mean Sq F value Pr(>F)
grupa       2    26.6  13.300  0.4512 0.6404
Residuals 36  1061.2  29.476

#isto dobijamo i sa komandom
summary(aov(lm(skola~grupa,data=podaci)))
```

Obeležje koje posmatramo u zadatku je broj poena koji kandidat nosi iz srednje škole. Faktor po kom radimo ANOVU je grupa u kojoj se kandidat nalazi i taj faktor ima tri nivoa: grupa A, grupa B i grupa C.

Testiramo hipotezu o jednakosti broja poena iz srednje škole u sve tri grupe.

$H_0(m_A = m_B = m_C)$ protiv $H_1(\exists i,j \,|\, m_i \neq m_j)$

Tabela ANOVE:

Df_1	$SSTR$	$MSTR$	F	α^*
Df_2	SSE	MSE		

$Df_1, Df_2 -$ stepeni slobode

$Df_1 = G - 1$, $Df_2 = n - G$, gde je G broj nivoa faktora po kom radimo ANOVU, a n je obim posmatranog uzorka.

$F -$ realizovana vrednost Fišerove test statistike sa stepenima slobode Df_1 i Df_2

Vrednost F dobijamo kao količnik $MSTR$ i MSE.

$\alpha^* - p$-vrednost $\rightarrow$ veličina kritične oblasti čija je granica registrovana vrednost test statistike

$\alpha^* = 0.6404 > \alpha = 0.05 \Rightarrow H_0$ se prihvata

Napomena:

Faktor po kom se radi ANOVA treba da bude kategorijalno obeležje (faktor). Ukoliko je obeležje numeričko, neophodno ga je prvo transformisati u faktor, pa tek onda raditi ANOVU.

```
>podaci<−read.csv("anova.csv")
#nazivi nivoa faktora iz fajla prijemni.csv su preimenovani u numericke vrednosti 1,2,3 umesto A,B,C
>anova(lm(skola~grupa,data=podaci))
Analysis of Variance Table

Response: skola
           Df  Sum Sq Mean Sq F value  Pr(>F)
grupa       1    22.2  22.204   0.771  0.3856
Residuals 37  1065.5  28.799
#Vidimo da broj stepeni nije dobar, pa onda ni p−vrednost nije odgovarajuca

>podaci$grupa<−as.factor(podaci$grupa)
> anova(lm(skola~grupa,data=podaci))
Analysis of Variance Table

Response: skola
           Df  Sum Sq Mean Sq F value  Pr(>F)
grupa       2    26.6  13.300  0.4512  0.6404
Residuals 36  1061.2  29.476
#Sada smo dobili iste vrednosti kao u zadatku 2.
```

Domaći rad

1. Proveriti šta rade sledeće komande (i dobijene rezultate uporediti sa ANOVOM):

```
prijemni<-read.csv("prijemni.csv")
oneway.test(skola~grupa,data=prijemni)
oneway.test(skola~grupa,data=prijemni,var.equal=TRUE)
```

2. Testirati hipotezu da su srednje vrednosti testa jednake za svih 5 udžbenika (ANOVA).

1 :	82	75	87	76
2 :	67	79	77	81
3 :	91	82	76	79
4 :	66	73	89	84
5 :	82	71	67	76

Prva ideja: "Peške" izračunati realizovanu vrednost test statistike F koristeći formule sa folija. (Koristiti R za brže izračunavanje traženih vrednosti.)

Druga ideja: Transformisati datu tabelu u data frame D i iskoristiti ugrađeni **anova** test iz R-a.

Linearna regresija najmanjih kvadrata

Učitati fajl prijemni.csv.

1. Napisati jednačinu linearne regresije uspeha iz srednje škole u zavisnosti od uspeha na prijemnom.

```
>podaci<-read.csv("prijemni.csv")
>lm(skola~prijemni,data=podaci)

Call:
lm(formula = skola ~ prijemni, data = podaci)

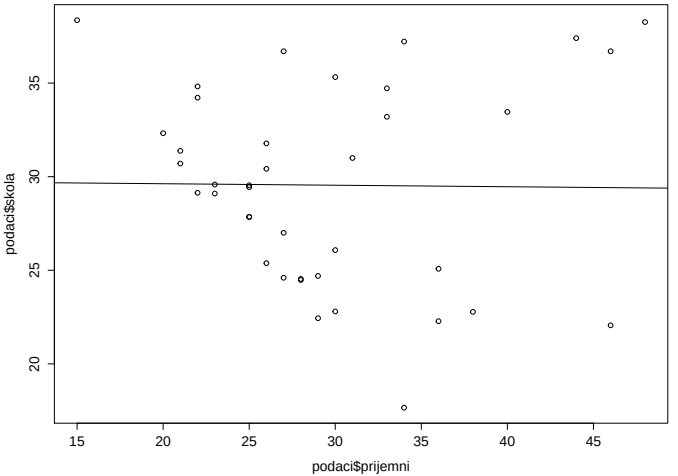
 Coefficients :
(Intercept)       prijemni
  29.784053    -0.008009
```

Jednačina linearne regresije

$$skola = -0.008009 * prijemni + 29.784053$$

2. Podatke predstaviti na dijagramu i nacrtati dobijenu pravu linearne regresije.

```
plot(podaci$prijemni,podaci$skola)
abline(lm(skola~prijemni,data=podaci))
```



3. Odrediti koeficijent korelacije uspeha iz srednje škole u zavisnosti od uspeha na prijemnom ispitu.

```
# koeficijent   korelacije
cor(podaci$skola,podaci$prijemni)
```

Koeficijent korelacije $r = -0.01157393$

$|r| < 0.3 \Rightarrow$ uspeh iz srednje škole i uspeh na prijemnom nisu u korelacionoj vezi

Napomena: Ako je $|r| < 0.3$ obeležja nisu u korelacionoj vezi, a za $0.3 \leq |r| \leq 0.7$ kažemo da postoji neznatna korelaciona veza. Ukoliko je $0.7 < |r| < 0.9$ postoji znatna korelaciona veza, a kada je $|r| \geq 0.9$ korelaciona veza je jaka.

4. Dati prognozu kom uspehu u srednjoj školi odgovara 35 bodova osvojenih na prijemnom ispitu.

```
#predikcija
lm(skola~prijemni,data=podaci)$coefficients %*% c(1,35)        #skalarno mnozenje vektora %*%
#-0.008009*35+29.784053
```

Na osnovu dobijenog linearnog modela vidimo da broju od 35 poena osvojenih na prijemnom odgovara 29.50375 poena iz srednje škole.

Ugrađeni statistički testovi

Po jedan uzorak sa dve mašine za pakovanje deterdženta od 10 kg izmeren je na preciznoj vagi.

- 9.81, 9.83, 10.43, 11.13, 9.70, 9.59, 10.88, 10.97, 9.35, 9.34, 9.41, 9.95, 11.03, 10.12, 9.33, 9.73, 10.17, 9.48, 10.89, 10.11, 10.30, 8.87, 9.51, 10.42, 10.02, 10.84, 9.96, 10.15, 10.64, 11.30
- 9.85, 9.30, 9.08, 8.07, 9.22, 9.55, 7.88, 7.84, 8.50, 11.95, 10.92, 9.78, 10.61, 9.49, 7.81, 8.90, 8.60, 8.50, 9.31, 9.97, 8.89, 8.87, 7.23, 7.82, 7.65, 9.11, 8.65, 6.30, 9.38, 8.31, 10.48, 10.56, 9.96, 8.84, 9.10, 11.07, 9.84, 9.75, 9.07, 9.09, 8.96, 8.11, 8.17, 9.73, 9.06, 8.40, 11.12, 9.38, 7.26, 8.69

```
uzorak1<-c(9.81, 9.83, 10.43, 11.13, 9.70, 9.59, 10.88, 10.97, 9.35, 9.34, 9.41, 9.95, 11.03, 10.12, 9.33, 9.73, 10.17, 9.48, 10.89, 10.11, 10.30, 8.87, 9.51, 10.42, 10.02, 10.84, 9.96, 10.15, 10.64, 11.30)

uzorak2<-c(9.85, 9.3, 9.08, 8.07, 9.22, 9.55, 7.88, 7.84, 8.5, 11.95, 10.92, 9.78, 10.61, 9.49, 7.81, 8.9, 8.6, 8.5, 9.31, 9.97, 8.89, 8.87, 7.23, 7.82, 7.65, 9.11, 8.65, 6.3, 9.38, 8.31, 10.48, 10.56, 9.96, 8.84, 9.10, 11.07, 9.84, 9.75, 9.07, 9.09, 8.96, 8.11, 8.17, 9.73, 9.06, 8.40, 11.12, 9.38, 7.26, 8.69)
```

1. Kolmogorov-Smirnov testom testirati hipotezu o saglasnosti prvog uzorka sa normalnom raspodelom $\mathcal{N}(10, 0.81)$.

```
> ks.test(uzorak1,'pnorm',10,0.81)                    #obavezno ' ' ili " "

  One-sample Kolmogorov-Smirnov test

data: uzorak1
D = 0.17074, p-value = 0.3097
alternative hypothesis: two-sided
```

$\alpha^* = 0.3097 > \alpha = 0.05 \Rightarrow$ hipoteza H_0 se prihvata

Napomena:

```
#realizovana vrednost test statistike
ks.test(uzorak1,'pnorm',10,0.81)$statistic*sqrt(length(uzorak1))
```

Vrednost $D = 0.17074$ je realizovana vrednost statistike $D_n = \sup_x |F_n^*(x) - F(x)|$.

Kako je $\sqrt{n_1}\, D = \sqrt{30} \cdot 0.17074 = 0.9351815 < 1.36$ zaključujemo da se hipoteza H_0 prihvata.

2. χ^2-testom testirati hipotezu o saglasnosti drugog uzorka sa normalnom raspodelom (deobne tačke: 8.0, 8.5, 9.0, 9.5, 10.0).

```
xn<-mean(uzorak2)                    #Prvo ocenjujemo nepoznate parametre m i sigma
sn<-sd(uzorak2)
m<-c(8,8.5,9,9.5,10)
pm<-pnorm(m,xn,sn)
p<-c(pm,1)-c(0,pm)
mi<-c(floor(min(uzorak2)),m,ceiling(max(uzorak2)))
fi<-hist(uzorak2,mi)$counts

y0<-chisq.test(fi,p=p)$statistic
y<-qchisq(.95,length(fi)-1-2)        #ocenili  smo dva parametra
```

$y_0 = 2.079539 < y = 7.814728 \Rightarrow$ hipoteza H_0 se prihvata

Napomena:

Pošto smo morali da ocenimo 2 parametra, $p-$vrednost koju vraća **chisq.test** nije tačna (ova vrednost bi bila tačna da nije bilo nepoznatih parametara) i moramo peške izračunati α^*.

```
#p-vrednost
alpha<-1-pchisq(y0,length(fi)-1-2)
```

$\alpha^* = 0.5560632 > \alpha = 0.05 \Rightarrow$ hipoteza H_0 se prihvata

3. Testirati hipotezu da je srednja vrednost prvog uzorka **za 1 veća** od srednje vrednosti drugog uzorka.

Želimo da testiramo hipotezu da razlika srednjih vrednosti prvog i drugog uzorka iznosi 1, tj. testiramo nultu hipotezu $H_0(m_1 - m_2 = 1)$ protiv alternativne hipoteze $H_1(m_1 - m_2 \neq 1)$.

```
> t.test(uzorak1,uzorak2,mu=1)

   Welch Two Sample t-test

data:  uzorak1 and uzorak2
t = 0.15013, df = 77.935, p-value = 0.8811
alternative hypothesis: true difference in means is not equal to 1
95 percent confidence interval:
 0.6436084 1.4145249
sample estimates:
mean of x mean of y
 10.10867  9.07960
```

$\alpha^* = 0.8811 > \alpha = 0.05 \Rightarrow$ hipoteza H_0 se prihvata

4. Testirati hipotezu da je srednja vrednost prvog uzorka **veća** od srednje vrednosti drugog uzorka.

Testiramo nultu hipotezu $H_0(m_1 = m_2)$ protiv alternativne hipoteze $H_1(m_1 > m_2)$.

```
> t.test(uzorak1,uzorak2,alternative='greater')      #alternative: two.sided (default), greater, less

  Welch Two Sample t-test

data: uzorak1 and uzorak2
t = 5.3151, df = 77.935, p-value = 4.929e-07
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 0.7067711       Inf
sample estimates:
mean of x mean of y
 10.10867  9.07960
```

$\alpha^* = 4.929 \cdot 10^{-7} < \alpha = 0.05 \Rightarrow$ hipoteza H_0 se odbacuje

Pošto smo odbacili nultu hipotezu prihvata se alternativna hipoteza H_1, tj. prihvata se hipoteza da je srednja vrednost prvog uzorka veća od srednje vrednosti drugog uzorka.

Napomena: Da smo stavili da je alternativna hipoteza $H_1(m_1 \neq m_2)$, dobili bismo $p-$vrednost $9.857 \cdot 10^{-7}$, koja je dva puta veća od $p-$vrednosti koja je dobijena za jednostrani test.

5. Testirati hipotezu da je srednja vrednost prvog uzorka veća od srednje vrednosti drugog, pod pretpostavkom da imaju jednake varijanse.

Ponovo testiramo $H_0(m_1 = m_2)$ protiv $H_1(m_1 > m_2)$.

```
> t.test(uzorak1,uzorak2,alternative='greater',var.equal=TRUE)

  Two Sample t-test

data:  uzorak1 and uzorak2
t = 4.6821, df = 78, p-value = 5.892e-06
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 0.6631998       Inf
sample estimates:
mean of x mean of y
 10.10867  9.07960
```

$\alpha^* = 5.892 \cdot 10^{-6} < \alpha = 0.05 \Rightarrow$ hipoteza H_0 se odbacuje, tj. prihvata se H_1

Napomena: Primetimo da se u ovom zadatku izračunavala vrednost Studentove test statistike sa 78 stepeni slobode, dok je u prethodnom zadatku broj stepeni slobode bio 77.935. U slučaju jednakih varijansi, broj stepeni slobode je $n_1 + n_2 - 2$, dok se kada nemamo pretpostavku o jednakosti varijansi za broj stepeni slobode u R-u uzima procena Welch-a: $\frac{\left(\frac{s_1'^2}{n_1} + \frac{s_2'^2}{n_2}\right)^2}{\frac{1}{n_1-1}\left(\frac{s_1'^2}{n_1}\right)^2 + \frac{1}{n_2-1}\left(\frac{s_2'^2}{n_2}\right)^2}$.

6. Testirati hipotezu da je standardna devijacija prvog uzorka jednaka 1.

```
n1<-length(uzorak1)
s<-sd(uzorak1)^2*(n1-1)/n1
y1<-qchisq((1+.95)/2,n1-1)
y2<-qchisq((1-.95)/2,n1-1)

x1<-n1*s/y1
x2<-n1*s/y2
```

Nulta hipoteza $H_0(\sigma = 1)$

$\sigma_0^2 = 1 \notin I = (0.2552004, 0.7271325) \Rightarrow$ hipoteza H_0 se odbacuje

Napomena:

Interval poverenja za σ je $I = (\sqrt{x_1}, \sqrt{x_2}) = (0.5051737, 0.8527206)$

7. Testirati hipotezu da je srednja vrednost drugog uzorka manja od 9.5 kg ako:
   a) $\sigma_2 = 1$ b) σ_2 nije poznato.

Testiramo nultu hipotezu $H_0(m_2 = 9.5)$ protiv alternativne hipoteze $H_1(m_2 < 9.5)$.

a) Koristimo jednostrani interval poverenja $I = \left(-\infty, \overline{X}_n + z\frac{\sigma}{\sqrt{n}}\right)$, sa kvantilom $z = \Phi^{-1}(\beta)$ umesto kvantila $z_\beta = \Phi^{-1}\left(\frac{1+\beta}{2}\right)$.

```
n2<-length(uzorak2)
xn<-mean(uzorak2)
sigma<-1
z<-qnorm(.95)

x2<-xn+z*sigma/sqrt(n2)
```

$m_0 = 9.5 \notin I = (-\infty, 9.312217) \Rightarrow$ hipoteza H_0 se odbacuje, tj. prihvata se H_1

Napomena:
Kod alternativne hipoteze $H_1(m > m_0)$ bi se gledao interval poverenja $I = \left(\overline{X}_n - z\frac{\sigma}{\sqrt{n}}, \infty\right)$.

b) Kada σ_2 nije poznato, možemo koristi **t.test** za jedan uzorak.

```
> t.test(uzorak2,mu=9.5,alternative="less")

   One Sample t-test

data:  uzorak2
t = -2.7095, df = 49, p-value = 0.004629
alternative hypothesis: true mean is less than 9.5
95 percent confidence interval:
     -Inf 9.33973
sample estimates:
mean of x
   9.0796
```

$\alpha^* = 0.004629 < \alpha = 0.05 \Rightarrow$ hipoteza H_0 se odbacuje, tj. prihvata se H_1

Napomena:

U okviru paketa **MKinfer** postoje funkcije pomoću kojih možemo odrediti intervale poverenja za očekivanje, kada znamo koliko je σ, kao i interval povarenja za standardnu devijaciju uzorka sa Normalnom raspodelom.

Zadatak 7, a) (slajd 78)

```
> meanCI(uzorak2,sd=1,alternative="less")

   Exact confidence interval (s)

95 percent confidence interval :
        0 %      95 %
mean  −Inf 9.312217

sample estimate:
  mean
9.0796

additional information:
SE of mean
 0.1414214
```

Zadatak 6 (slajd 77)

```
> sdCI(uzorak1)

   Exact confidence interval (s)

95 percent confidence interval :
         2.5 %     97.5 %
sd 0.5051737 0.8527206

sample estimates:
      mean         sd
10.108667 0.634316

additional information:
SE of mean
 0.1158097
```

Funkcija **normCI** iz pomenutog paketa vraća odgovarajuće intervale poverenja i za očekivanje i za standardnu devijaciju.

8. Testirati hipotezu da su standardne devijacije kod oba uzorka jednake.

Testiramo nultu hipotezu $H_0(\sigma_1^2 = \sigma_2^2)$ protiv alternativne $H_1(\sigma_1^2 \neq \sigma_2^2)$.

```
> var.test(uzorak1,uzorak2)

  F test to compare two variances

data: uzorak1 and uzorak2
F = 0.33427, num df = 29, denom df = 49, p-value = 0.002289
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.1776679 0.6653103
sample estimates:
ratio of variances
         0.3342673
```

$\alpha^* = 0.002289 < \alpha = 0.05 \Rightarrow$ hipoteza H_0 se odbacuje

Napomena: Pre sprovođenja **t.test**–a bi trebalo uraditi **var.test**, da utvrdimo koju varijantu t–testa treba koristiti.

Napomena:

Realizovanu vrednost Fišerove test statistike možemo dobiti i na sledeći način:

$$F = \frac{\frac{n_1 \overline{S}^2_{n_1}}{n_1 - 1}}{\frac{n_2 \overline{S}^2_{n_2}}{n_2 - 1}} = \frac{\overline{S}'^2_{n_1}}{\overline{S}'^2_{n_2}}.$$

Ova statistika ima Fišerovu raspodelu sa stepenima slobode $n_1 - 1$ i $n_2 - 1$.

```
n1<-length(uzorak1)
n2<-length(uzorak2)
s1<-sd(uzorak1)^2*(n1-1)/n1
s2<-sd(uzorak2)^2*(n2-1)/n2

F<-n1*s1*(n2-1)/(n2*s2*(n1-1))          #var(uzorak1)/var(uzorak2)
```

9. Testirati hipotezu da je procenat pakovanja koja imaju manje od 8.5 kg u drugom uzorku 20%, koristeći aproksimaciju Moavr-Laplasovom teoremom.

Testiramo $H_0(p = 0.2)$ protiv $H_1(p \neq 0.2)$

```
>K<-length(which(uzorak2<8.5))
>n2<-length(uzorak2)

> prop.test(K,n2,.2,correct=FALSE)

  1-sample proportions test without continuity correction

data: K out of n2, null probability 0.2
X-squared = 1.125, df = 1, p-value = 0.2888
alternative hypothesis: true p is not equal to 0.2
95 percent confidence interval:
 0.1587153 0.3955316
sample estimates:
   p
0.26
```

$\alpha^* = 0.2888 > \alpha = 0.05 \Rightarrow$ hipoteza H_0 se prihvata

Napomena: Stavljamo correct=FALSE da ne umanji grešku zaokruživanja koja nastaje kao posledica aproksimacije diskretne slučajne promenljive neprekidnom.

$*$ Ispitati nezavisnost obeležja X i Y čije su realizovane vrednosti uzorka:

5	18	9
6	7	20

(tabela kontigencije – slajd 58)

```
> chisq.test(matrix(c(5,6,18,7,9,20),2,3))

  Pearson's Chi-squared test

data:  matrix(c(5, 6, 18, 7, 9, 20), 2, 3)
X-squared = 9.0901, df = 2, p-value = 0.01062
```

H_0 : obeležja X i Y su nezavisna

$\alpha^* = 0.01062 < \alpha = 0.05 \Rightarrow$ hipoteza H_0 se odbacuje

Domaći rad

Koristeći ugrađene statističke testove u R–u uraditi

1. zadatke iz parametarskih i neparametarskih testova koje smo ranije radili
2. domaći nakon neparametarskih testova (slajd 62)

Testovi normalnosti

Velika većina testova koje smo do sada radili ima pretpostavku da uzorak ima Normalnu $\mathcal{N}(m,\sigma)$ raspodelu. Zato je pre sprovođenja tih testova potrebno testirati nultu hipotezu $H_0(F(x) = \Phi(\frac{x-m}{\sigma}))$ protiv alternativne hipoteze $H_1(F(x) \neq \Phi(\frac{x-m}{\sigma}))$.

1. Kolmogorov-Smirnov test (samo ako iz iskustva znamo vrednosti parametara m i σ)
2. Shapiro-Wilk test

```
> prijemni<-read.csv("prijemni.csv")
> shapiro.test(prijemni$skola)

   Shapiro-Wilk normality test

data:  prijemni$skola
W = 0.9675, p-value = 0.3138
```

Napomena:

Paket **nortest** sadrži nekoliko testova normalnosti, od kojih su najpoznatiji Anderson-Darling test (**ad.test**) i Cramér-von Mises test (**cvm.test**).

t-test parova

10 osoba je izmereno pre i nakon 10 nedelja dijete i zabeleženi su sledeći rezultati:

pre	76.05	82.56	72.97	85.96	56.80	79.96	54.98	109.30	66.07	87.64
posle	76.46	76.65	70.82	83.73	60.22	74.53	50.38	110.38	64.68	85.19

Testirati hipotezu da je razlika srednjih vrednosti težina pre i posle dijete veća od 0.

U pitanju je specijalan slučaj t-testa kod kog obeležja imaju uparene vrednosti ("pre i posle"). Želimo da testiramo da li je dijeta imala efekta i da li su kandidati izgubili na težini, tj. testiramo nultu hipotezu $H_0(m_1 - m_2 = 0)$ protiv alternativne hipoteze $H_1(m_1 - m_2 > 0)$.

```
> wgt1<-c(76.05,82.56,72.97,85.96,56.80,79.96,54.98,109.30,66.07,87.64)
> wgt2<-c(76.46,76.65,70.82,83.73,60.22,74.53,50.38,110.38,64.68,85.19)

> shapiro.test(wgt1)
  Shapiro-Wilk normality test
data: wgt1
W = 0.95439, p-value = 0.7204
> shapiro.test(wgt2)
  Shapiro-Wilk normality test
data: wgt2
W = 0.94676, p-value = 0.6304
```

Pošto je ispunjena pretpostavka o normalnosti oba uzorka, možemo iskoristiti t-test parova.

```
> t.test(wgt1, wgt2, paired=TRUE, alternative="greater")

  Paired t-test

data:  wgt1 and wgt2
t = 2.0536, df = 9, p-value = 0.0351
alternative hypothesis: true difference in means is greater than 0
95 percent confidence interval:
 0.2067164       Inf
sample estimates:
mean of the differences
                 1.925
```

$\alpha^* = 0.0351 < \alpha = 0.05 \Rightarrow$ hipoteza H_0 se odbacuje, tj. prihvata se H_1

Napomena: Kada radimo "peške", umesto obeležja X i Y posmatra se novo obeležje $T = X - Y$ i testiramo hipotezu da je očekivanje obeležja T jednako 0 (pri čemu σ nije poznato).

```
t.test(wgt1-wgt2, alternative="greater")
```

Tabela kontigencije

Ispitati nezavisnost obeležja pol i grupa iz fajla prijemni.csv.

```
> prijemni<-read.csv("prijemni.csv")
> table(prijemni$pol, prijemni$grupa)                    #pravimo tabelu frekvencija

    A  B  C
  m 14 13 5
  z  1  4  2

> chisq.test(table(prijemni$pol, prijemni$grupa))

  Pearson's Chi-squared test

data:  table(prijemni$pol, prijemni$grupa)
X-squared = 2.1923, df = 2, p-value = 0.3342

Warning message:
In chisq.test(table(prijemni$pol, prijemni$grupa)) :
  Chi-squared approximation may be incorrect
```

$\alpha^* = 0.3342 > \alpha = 0.05 \Rightarrow$ obeležja pol i grupa su nezavisna

Napomena: Greška koju R javlja je posledica činjenice da su neke frekvencije iz tabele veoma male.

Multipla (višestruka) regresija

Učitati fajl MnGroundwater.csv. Pronaći linearnu zavisnost pH vrednosti vode od količine aluminijuma (Al), arsena (As), hlora (Cl) i olova (Pb).

```
> D<−read.csv("MnGroundwater.csv")
> model1<−lm(pH~Aluminum+Arsenic+Chloride+Lead,data=D)
> model1

Call:
lm(formula = pH ~ Aluminum + Arsenic + Chloride + Lead, data = D)

Coefficients :
(Intercept)     Aluminum      Arsenic     Chloride         Lead
  7.289e+00   5.646e−04   −3.342e−03   −5.487e−08   −5.906e−04
```

$$pH = 5.646 \cdot 10^{-4} Al - 3.342 \cdot 10^{-3} As - 5.487 \cdot 10^{-8} Cl - 5.906 \cdot 10^{-4} Pb + 7.289$$

Postavljaju se sledeća pitanja:

1. Da li je dobijeni model statistički značajan?
2. Da li je dobijeni model koristan?
3. Da li su (svi) koeficijenti statistički značajni? Ukoliko nisu, koji prediktor možemo izbaciti iz razmatranja?

Summary dobijenog modela daje odgovore na postavljena pitanja.

```
> summary(model1)

Call:
lm(formula = pH ~ Aluminum + Arsenic + Chloride + Lead, data = D)

Residuals:
     Min       1Q   Median       3Q      Max
-5.7889  -0.2535  -0.0388   0.2128   2.1267

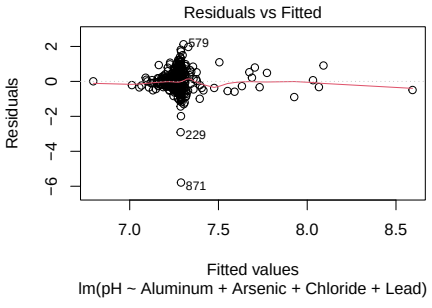
Coefficients :
             Estimate   Std. Error   t value   Pr(>|t|)
(Intercept)  7.289e+00   1.830e-02   398.261   < 2e-16 ***
Aluminum     5.646e-04   1.168e-04     4.835   1.57e-06 ***
Arsenic     -3.342e-03   1.502e-03    -2.225      .0264 *
Chloride    -5.487e-08   9.168e-08    -0.599     0.5496
Lead        -5.906e-04   1.739e-03    -0.340     0.7343
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

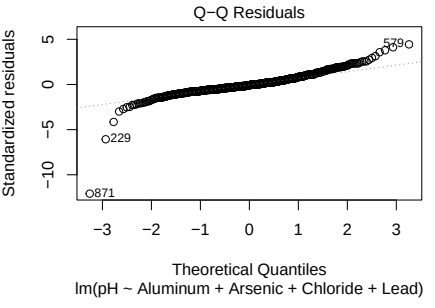
Residual standard error: 0.4793 on 890 degrees of freedom
Multiple R-squared: 0.03171, Adjusted R-squared: 0.02736
F-statistic: 7.286 on 4 and 890 DF, p-value: 8.957e-06
```

Reziduali predstavljaju razliku između zabeležene vrednosti pH vode i vrednosti koju je R izračunao na osnovu dobijenog modela. Oni nam govore koliko je dobro model prilagođen podacima (koliko dobro model fituje podatke). Obično se proverava da li reziduali imaju Normalnu raspodelu, kao i da li je zbir svih reziduala približno jednak nuli.

```
residuals(model1)                 # ispisuje  reziduale
sum(residuals(model1))            #treba da bude blizu  0

plot(model1,which=1)              #plot reziduala
plot(model1,which=2)              #QQ-plot
```





Coefficients :

	Estimate	Std. Error	**t** value	Pr(>|**t**|)	
(Intercept)	7.289e+00	1.830e−02	398.261	< 2e−16	***
Aluminum	5.646e−04	1.168e−04	4.835	1.57e−06	***
Arsenic	−3.342e−03	1.502e−03	−2.225	.0264	*
Chloride	−5.487e−08	9.168e−08	−0.599	0.5496	
Lead	−5.906e−04	1.739e−03	−0.340	0.7343	

− − −

Signif. **codes**: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 '␣' 1

Želimo da vidimo koliko je svaki **koeficijent statistički značajan** za dobijeni model. Koeficijent je značajan ukoliko je njegova vrednost različita od 0, tj. ukoliko koeficijent doprinosi modelu. Dakle, testiramo nultu hipotezu da je koeficijent jednak nuli, nasuprot alternativnoj hipotezi da je koeficijent različit od nule. Prema tome, koeficijenti koji imaju velike $p-$vrednosti nisu statistički značajni, dok oni sa malim $p-$vrednostima jesu.

Zgodan način za utvrđivanje da li je neki koeficijent statistički značajan je pomoću "significance codes". Naime, svi koeficijenti koji su označeni sa zvezdicama su statistički značajni. Što je veći broj zvezdica, to je koeficijent značajniji za dobijeni model.

Multiple $\mathbf{R}-$squared: 0.03171, Adjusted $\mathbf{R}-$squared: 0.02736

Koeficijent determinacije r^2 nam daje meru slaganja regresione prave sa eksperimentalnim podacima i dobija se kao količnik varijansi. Na osnovu koeficijenta determinacije zaključujemo da li je model **koristan** ili ne. Što je koeficijent determinacije bliži broju 1, model je korisniji jer imamo bolje slaganje modela sa eksperimentalnim podacima. Problem sa ovim koeficijentom je što počinje da raste kako se dodaju prediktori, bez obzira što nisu svi koeficijenti statistički značajni. Zbog toga je kod multiple regresije bolje posmatrati podešeni koeficijent determinacije, koji uzima u obzir i broj posmatranih prediktora.

F$-$ statistic : 7.286 **on** 4 and 890 DF, p$-$value: 8.957e$-$06

Sada želimo da utvrdimo da li postoji veza između zavisne promenljive pH i nezavisnih promenljivih Al, As, Cl i Pb. Testiramo nultu hipotezu da ne postoji zavisnost, protiv alternativne hipoteze da je zavisnost prisutna. Tačnije, nulta hipoteza glasi da su svi koeficijenti u modelu jednaki nula, dok alternativna hipoteza tvrdi da postoji nenula koeficijent. Pomoću ovog testa zaključujemo da li je sam **model statistički značajan**. Vidimo da ukoliko je $p-$vrednost modela mala, model će biti značajan, tj. bar jedan koeficijent u modelu će biti različit od nule. Takođe, ukoliko je realizovana vrednost Fišerove test statistike veća od 1, model je značajan.

Napomena: Stepeni slobode $Df_1 =$ broj prediktora, $Df_2 =$ obim uzorka - 1 - broj prediktora

1. Da li je dobijeni model statistički značajan?

   $p-$vrednost: $8.957 \cdot 10^{-6} < 0.05 \Rightarrow$ model je statistički značajan

   (Što je $p-$vrednost manja, model je značajniji.)

2. Da li je dobijeni model koristan?

   Koeficijent determinacije r^2 : 0.03171
   Podešeni koeficijent determinacije: 0.02736

   Pošto je podešeni koeficijent determinacije blizak nuli, dobijeni model nije koristan, pa prema tome regresiona prava ne opisuje najbolje eksperimentalne podatke.

3. Da li su (svi) koeficijenti statistički značajni? Ukoliko nisu, koji prediktor možemo izbaciti iz razmatranja?

   Koeficijenti koji stoje uz hlor i olovo nisu statistički značajni (velike $p-$vrednosti) i te prediktore možemo zanemariti u daljem razmatranju. Pravimo novi model koji ima dva prediktora manje od prethodnog.

   model2<-lm(pH∼Aluminum+Arsenic,data=D)

$$pH = 5.614 \cdot 10^{-4} Al - 3.316 \cdot 10^{-3} As + 7.287$$

Postavlja pitanje da li postoje statistički značajne razlike između modela 1 i modela 2?

Testiraćemo nultu hipotezu da ne postoje razlike između modela, protiv alternativne hipoteze da statistički značajne razlike postoje.

```
> anova(model1, model2)
Analysis of Variance Table

Model 1: pH ~ Aluminum + Arsenic + Chloride + Lead
Model 2: pH ~ Aluminum + Arsenic
  Res.Df    RSS  Df  Sum of Sq      F  Pr(>F)
1    890 204.48
2    892 204.59  -2  -0.10992 0.2392  0.7873
```

$Df_2 = -2$: model 2 ima 2 prediktora manje od modela 1

$p-$vrednost: 0.7873 $\Rightarrow$ ne postoji statistički značajna razlika između ova dva modela

Predikcije

$Al : 25,\ As : 2,\ Cl : 1350,\ Pb : 0.5 \quad \Rightarrow \quad pH = ?$

```
#1. nacin
model1$coefficients%*%c(1, 25, 2, 1350, 0.5)          #skalarno mnozenje vektora

#2. nacin
v<-data.frame(Aluminum=25, Arsenic=2, Chloride=1350, Lead=0.5)
predict(model1, newdata = v)
```

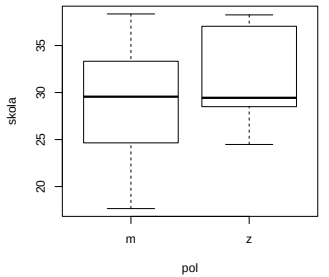
$$\begin{aligned} pH &= \mathbf{25} \cdot 5.646 \cdot 10^{-4} - \mathbf{2} \cdot 3.342 \cdot 10^{-3} - \mathbf{1350} \cdot 5.487 \cdot 10^{-8} - \mathbf{0.5} \cdot 5.906 \cdot 19^{-4} + 7.289 \\ &= 7.296325 \end{aligned}$$

Napomena: U drugom načinu data frame mora imati kolone koje su nazvane kao prediktori.

Permutacioni testovi

Koristeći permutacioni test testirati hipotezu o jednakosti srednje vrednosti uspeha iz škole kod muških i ženskih kandidata iz fajla prijemni.csv.

```
prijemni<-read.csv("prijemni.csv")
boxplot(skola~pol,data=prijemni)
```



Želimo da testiramo hipotezu $H_0(m_m = m_z)$ protiv $H_1(m_m \neq m_z)$ i to ćemo uraditi sa permutacionom verzijom t–testa. Prednost permutacionih testova je što oni ne zahtevaju da bude ispunjena pretpostavka o normalnosti posmatranog uzorka.

```
prijemni$pol<-as.factor(prijemni$pol)
summary(prijemni) #m:32, z:7

xn<-tapply(prijemni$skola,prijemni$pol,mean)
#umesto xn<-c(mean(prijemni$skola[prijemni$pol=="m"]),mean(prijemni$skola[prijemni$pol=="z"]))

reg.razlika<-xn[1]-xn[2]                    #registrovana razlika srednjih vrednosti
```

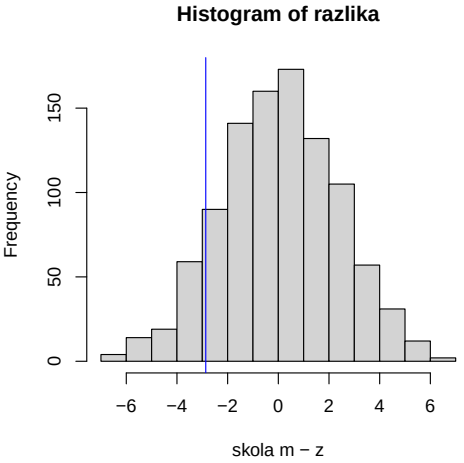
Ukoliko nema razlike između broja poena kod muških i ženskih kandidata, onda je svejedno kako smo napravili podelu posmatranog uzorka na dva dela (jedan sa 32 kandidata, drugi sa 7 kandidata). Traženje razlike srednjih vrednosti za svih $\binom{39}{32} = 15\,380\,937$ mogućih uzoraka predstavlja preobiman posao i zbog toga se radi **reuzorkovanje** (ponovno uzorkovanje – resampling).

```
#ponovno uzorkovanje (resampling)
N<-999
razlika<-numeric(N)
for (i in 1:N){
  indeks<-sample(39,size=32,replace=FALSE)
  razlika[i]<-mean(prijemni$skola[indeks])-mean(prijemni$skola[-indeks])
}
```

Napomena: Reuzorkovanje se generalno radi sa vraćanjem (zbog nezavisnosti). Za dovoljno veliki obim uzorka, verovatnoće koje se dobijaju kada se radi sa vraćanjem i bez vraćanja su približno iste.

```
#histogram permutacione raspodele
hist(razlika,xlab="skola m - z")
abline(v=reg.razlika,col="blue")                    #vertikalna prava u vrednosti originalne razlike
```

Na primer:



Kako prvu registrovanu razliku imamo na osnovu zadatog uzorka, i nju ćemo takođe računati. Iz tog razloga smo reuzorkovanje radili 999 puta (sve ukupno 1000 puta). Ovo se radi da bi se izbeglo da $p-$vrednost eventualno bude jednaka nuli.

```
#p−vrednost
2*(sum(razlika <= reg.razlika) + 1)/(N + 1)

#Jednostrani test: (sum(razlika <= reg.razlika) + 1)/(N + 1)
```

Permutaciona raspodela je promenljiva zbog slučajnog uzorkovanja, pa se p–vrednost i histogram permutacione raspodele takođe menjaju.

$\alpha^* \sim 0.2 > \alpha = 0.05 \Rightarrow$ hipoteza H_0 se prihvata

Napomena: Da smo stavili da je reg.razlika<-xn[2]-xn[1], p–vrednost bi računali na sledeći način:

2*(sum(razlika >= reg.razlika) + 1)/(N + 1).

Da ne bismo morali da vodimo računa da li je vrednost registrovane razlike bila pozitivna ili negativna, "bolji" način za izračunavanje $p-$vrednosti kod dvostranog testa je sledeći:

(sum(abs(razlika)>=abs(reg.razlika))+1)/(N+1).

$*$ Pošto je u zadatku ispunjena pretpostavka o normalnosti oba uzorka, zadatak je mogao biti rešen i korišćenjem t-testa.

```
> shapiro.test(prijemni$skola[prijemni$pol=="m"])
> shapiro.test(prijemni$skola[prijemni$pol=="z"])

> t.test(prijemni$skola[prijemni$pol=="m"],prijemni$skola[prijemni$pol=="z"])

   Welch Two Sample t-test

data:  prijemni$skola[prijemni$pol == "m"] and prijemni$skola[prijemni$pol == "z"]
t = -1.2648, df = 8.6296, p-value = 0.239
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -8.018601 2.291815
sample estimates:
mean of x mean of y
 29.03375 31.89714
```

$\alpha^* = 0.239 > \alpha = 0.05 \Rightarrow$ hipoteza H_0 se prihvata

Napomena: U već spominjanom paketu **MKinfer** postoji funkcija za permutacioni t–test.

```
> perm.t.test(prijemni$skola[prijemni$pol=="m"],prijemni$skola[prijemni$pol=="z"],R=999)

   Permutation Welch Two Sample t-test

data:  prijemni$skola[prijemni$pol == "m"] and prijemni$skola[prijemni$pol == "z"]
number of permutations: 999
(Monte-Carlo) permutation p-value = 0.2302
permutation difference of means (SE) = -2.892133 (2.20471)
95 percent (Monte-Carlo) permutation percentile confidence interval:
 -7.266589 1.330647

Results without permutation:
t = -1.2648, df = 8.6296, p-value = 0.239
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -8.018601 2.291815
sample estimates:
mean of x mean of y
 29.03375 31.89714
```

Drugi deo testa (Results without permutation) daje rezultat za običan t–test.

Primetimo da prvi deo testa ispisuje različite vrednosti kada se test ponovo pozove.